

What the Fuck Is Going On Inside an LLM?

Атлас · единое содержание

Редакция 4.1 · 27 сентября 2026

7 блоков · 82 глав · 945 подтем. Все 763 пункта редакции 3.0 сохранены с прежними номерами; добавлено 182.

Порядок обучения в блоке 7: постановка нагрузки → устройство железа → промышленное обучение и инференс → данные и БД → локальная модель → расчёт памяти → дообучение → подбор компонентов → сервер → практикум → испытания. Существующие 3.3, 3.7 и 6.18 дают теоретические переходы; блок 7 доводит их до измерений и выбора конкретной конфигурации.

Это содержание и план опытов. Числа из практикума — приблизительная арифметика весов, а не список гарантированно запускаемых моделей. 16–32 GiB VRAM могут хватить отдельным квантизованным 20B, но не обычному полному обучению 20B на одной карте. Утверждения и версия программного стека уточняются по документации и контрольному запуску.

Блок 1. Математические основания, информация и теория обучения

Блок 2. Представления, архитектуры и генеративные модели

Блок 3. Данные, обучение, масштабирование и вычислительная инженерия

Блок 4. Постобучение, рассуждение и проверка решений

Блок 5. Внутренние механизмы, надёжность и безопасность

Блок 6. Профессиональное использование, знания и агентные системы

Блок 7. Вычислительное железо, инфраструктура и локальные модели

Блок 1. Математические основания, информация и теория обучения

1.1. Линейная алгебра, геометрия и анализ

- 1.1.1 Векторы и пространства: координаты, базис и смена представления
- 1.1.2 Нормы и скалярное произведение: длина, угол и сходство
- 1.1.3 Матрицы: линейное преобразование и композиция операций
- 1.1.4 Проекции, ранг и SVD: сокращение размерности и потеря информации
- 1.1.5 Производная и градиент: локальное изменение функции
- 1.1.6 Цепное правило: основа обратного распространения
- 1.1.7 Оптимизация и устойчивость: шаг, обусловленность и численные ошибки
- 1.1.8 Высокая размерность: почему привычная геометрическая интуиция требует проверки
- 1.1.9 Гипотеза многообразия и внутренняя размерность
- 1.1.10 Дифференциальная геометрия: касательные пространства, метрика, геодезические и кривизна
- 1.1.11 Геометрия активаций: выбор состояния, внутренняя размерность и проверяемость гипотезы о траектории рассуждения

1.2. Вероятность, информация и статистический вывод

- 1.2.1 Условная вероятность и Байес: обновление знания
- 1.2.2 Распределения и оценивание: параметры по наблюдениям
- 1.2.3 Выборка и неопределённость: интервалы и повторяемость
- 1.2.4 Множественные проверки: риск случайно найденных закономерностей
- 1.2.5 Причинность и ассоциация: какие допущения нужны для вывода о воздействии
- 1.2.6 Перестановочные нулевые модели: влияние размера выборки, ширины и глубины сети на метрики
- 1.2.7 Структурные причинные модели, вмешательства, контрфактуальные вопросы и идентифицируемость
- 1.2.8 Conformal prediction: множества ответов, покрытие, обменность и нарушения предпосылок

1.3. Теория информации, сжатие и описание данных

- 1.3.1 Энтропия и перекрёстная энтропия: неопределённость и функция потерь
- 1.3.2 KL-дивергенция: сравнение распределений с учётом направления
- 1.3.3 Теория сжатия и информационного горлышка
- 1.3.4 Колмогоровская сложность, алгоритмическая информация и MDL
- 1.3.5 Взаимная информация и условная энтропия
- 1.3.6 Кодирование источника и связь с предсказанием следующего токена
- 1.3.7 Rate-distortion: компромисс между сжатием и потерей информации
- 1.3.8 Несмещённость, оценимость и ограничения информационных объяснений обучения

1.4. Марковские модели и скрытые состояния

- 1.4.1 Матрица переходов: вероятностная динамика конечной системы
- 1.4.2 Стационарное распределение и эргодичность: долгосрочное поведение
- 1.4.3 N-граммы и сглаживание: классическое моделирование текста
- 1.4.4 НММ: наблюдения и скрытые состояния
- 1.4.5 Прямой и обратный алгоритмы: вероятности и вывод
- 1.4.6 Витерби и обучение НММ: наиболее вероятный путь и параметры
- 1.4.7 MCMC: получение выборок из сложного распределения
- 1.4.8 MDP и POMDP: действия, награды и частичная наблюдаемость

1.5. Основы машинного обучения

- 1.5.1 Регрессия и классификация: разные типы предсказаний
- 1.5.2 Обучающая, проверочная и тестовая выборки: назначение разделения
- 1.5.3 Переобучение и регуляризация: управление сложностью
- 1.5.4 Деревья, ансамбли и SVM: сравнение с нейронными моделями
- 1.5.5 Кластеризация и снижение размерности: исследование структуры
- 1.5.6 Сдвиг распределения и утечки: почему оценка перестаёт работать

1.6. Нейронные сети и обучение

- 1.6.1 MLP и нелинейности: какие функции может представить сеть
- 1.6.2 Вычислительный граф и автодифференцирование: от формулы к градиенту
- 1.6.3 Инициализация и нормализация: устойчивость сигнала
- 1.6.4 Оптимизаторы и расписания: движение по функции потерь
- 1.6.5 Регуляризация и диагностика: ошибки обучения и обобщения
- 1.6.6 CNN: локальность и разделение параметров
- 1.6.7 Численный эксперимент: воспроизведение маленькой сети
- 1.6.8 Forward-Forward и локальное обучение без стандартного backprop

1.7. Теория обобщения и динамика обучения

- 1.7.1 PAC, VC-размерность и сложность Радемахера
- 1.7.2 Байесовское обучение, априорные допущения и PAC-Bayes
- 1.7.3 Bias-variance, интерполяция и двойной спуск
- 1.7.4 Неявная регуляризация SGD и геометрия функции потерь
- 1.7.5 Статистическая физика больших систем, mean-field и NTK
- 1.7.6 Grokking и переход от запоминания к обобщению
- 1.7.7 Какие теоретические результаты переносятся на конечные LLM
- 1.7.8 Формальные языки и выразительность: автоматы, компактность Transformer и сложность проверки
- 1.7.9 Ёмкость запоминания: определение единицы информации, размер модели и отличие от обобщения

Блок 2. Представления, архитектуры и генеративные модели

2.1. История языкового моделирования

- 2.1.1 Предсказание последовательностей: откуда возникает задача языковой модели
- 2.1.2 Символический подход: правила, знания и ограничения ручного описания
- 2.1.3 Статистический поворот: оценивание по корпусам
- 2.1.4 Нейронный поворот: совместное обучение признаков и предсказания
- 2.1.5 Модели общего назначения: перенос между задачами
- 2.1.6 Исторические свидетельства: отличать первоисточник от поздней интерпретации

2.2. Последовательности и история представлений

- 2.2.1 Нейронная языковая модель: обучаемое распределённое представление
- 2.2.2 RNN, LSTM и GRU: перенос состояния по последовательности
- 2.2.3 Seq2seq и внимание: связь входной и выходной последовательностей
- 2.2.4 Word2vec: обучение по локальному контексту
- 2.2.5 GloVe: статистика совместных встречаемостей
- 2.2.6 FastText: подсловная структура в представлении слова
- 2.2.7 ELMo: зависимость представления от контекста

2.3. Токенизация и сериализация

- 2.3.1 Символы и байты: кодировка и границы единиц
- 2.3.2 BPE, WordPiece и unigram: разные процедуры построения словаря
- 2.3.3 Специальные токены и шаблон диалога: формат взаимодействия
- 2.3.4 Русский язык и многоязычие: покрытие и фрагментация
- 2.3.5 Числа, код и редкие слова: проблемные входы
- 2.3.6 Изменение токенизатора: совместимость с весами модели
- 2.3.7 Модели без фиксированного словаря: байтовые и символьные представления, длина и стоимость

2.4. Эмбединги и обучение представлений

- 2.4.1 Слово, предложение и документ: разные единицы представления
- 2.4.2 Косинусная близость: угол и условия содержательной интерпретации
- 2.4.3 Анизотропия и концентрация: геометрические искажения
- 2.4.4 Контрастивное обучение и отрицательные примеры: формирование пространства
- 2.4.5 Bi-encoder и cross-encoder: представление отдельно и совместное сравнение
- 2.4.6 Pooling и многовекторные модели: сохранение информации
- 2.4.7 Matryoshka: представления разной размерности
- 2.4.8 Оценка: сходство, классификация и поиск как разные задачи
- 2.4.9 Линейная гипотеза представлений: концепты, probing, steering и выбор скалярного произведения
- 2.4.10 Платоническая и аристотелевская гипотезы: глобальная структура, локальные соседства и расстояния
- 2.4.11 Сравнение представлений: СКА, ССА, соседства, калибровка и нулевые контроли
- 2.4.12 Выравнивание пространств: Procrustes, линейные и нелинейные отображения, парные и непарные данные

- 2.4.13 Оптимальный транспорт: Wasserstein, Gromov–Wasserstein, якоря и неоднозначность соответствия
- 2.4.14 Перенос между энкодерами: vec2vec, идентифицируемость и проверка сохранения смысла

2.5. Transformer изнутри

- 2.5.1 Q, K и V: как вычисляется внимание
- 2.5.2 Self-attention и cross-attention: разные источники информации
- 2.5.3 Маски: доступ к позициям и причинное предсказание
- 2.5.4 Позиционные представления: порядок в последовательности
- 2.5.5 Остаточные связи, нормализация и MLP: устройство блока
- 2.5.6 Многоголовое внимание и его варианты: ёмкость и стоимость
- 2.5.7 Прямой проход: размеры тензоров и вычисления
- 2.5.8 Softmax, масштабирование логитов и численная устойчивость
- 2.5.9 Квадратичная зависимость полного внимания от длины контекста: вычисления и память
- 2.5.10 Выходная проекция, weight tying и распределение следующего токена
- 2.5.11 Вычислительная выразительность Transformer: точность чисел, длина входа и допущения формальной модели

2.6. Семейства моделей и модельные роли

- 2.6.1 Encoder, decoder и encoder-decoder: различия целей
- 2.6.2 BERT, GPT и T5: исторические архитектурные линии
- 2.6.3 Base, instruct и reasoning: роль последующего обучения
- 2.6.4 Плотные модели и MoE: параметры и маршрутизация
- 2.6.5 Малые и большие модели: критерии выбора
- 2.6.6 Генератор, ранжировщик, судья и политика: разные роли
- 2.6.7 Открытые и закрытые системы: какие свойства проверяемы
- 2.6.8 Сравнительная анатомия архитектур. Разбирать модели по одинаковым осям: внимание, состояние, нормализация, FFN/MoE, позиционное кодирование, память и вычисления
- 2.6.9 Token-choice и expert-choice маршрутизация
- 2.6.10 MoE: балансировка нагрузки, capacity, shared experts и коммуникация all-to-all

2.7. Альтернативные и гибридные архитектуры

- 2.7.1 Модели пространства состояний: динамика и селективность
- 2.7.2 Линейное внимание: приближения и ограничения
- 2.7.3 Современная рекуррентность: состояние вместо полного контекста
- 2.7.4 Гибридные архитектуры: сочетание механизмов
- 2.7.5 Обучаемая память: обновление информации во время работы
- 2.7.6 Сравнение: задержка, память, длина последовательности и качество
- 2.7.7 Селективные SSM и Mamba: дискретизация, scan и аппаратная реализация
- 2.7.8 Neural ODE и жидкие сети: непрерывная динамика и способы обучения
- 2.7.9 Квантовые состояния, измерение, кодирование данных и ограничения квантового преимущества
- 2.7.10 Рекуррентность по токенам и повторение слоя по глубине: разные оси вычисления
- 2.7.11 Looped Transformer, Universal Transformer, Huginn и Ouro: общие блоки, состояние и остановка

- 2.7.12 Recurrent Looped Transformer (RLT): каузальный энкодер, глобальная KV-память, скользящее внимание декодера и перенос состояния
- 2.7.13 RLT: обработка prompt и ответа одним переходом; состояние, кэши, градиенты и повторное воспроизведение траектории
- 2.7.14 Проверка заявлений о RLT: эффективная и временная глубина, параллелизм, скорость, обучение, качество и сопоставимые базовые модели

2.8. Проектирование LLM: от требований к архитектуре

- 2.8.1 Бюджет качества, памяти, задержки и обучающих данных
- 2.8.2 Выбор глубины, ширины, числа голов и размера FFN
- 2.8.3 MHA, MQA, GQA, латентное и локальное внимание
- 2.8.4 RoPE и расширение контекста: экстраполяция и её проверка
- 2.8.5 Плотная модель, MoE, рекуррентная и гибридная модель
- 2.8.6 Состояние модели: KV-cache, SSM и внешняя память
- 2.8.7 Архитектура, целевая функция и режим обучения как совместный выбор
- 2.8.8 Один полный проход: тензоры, параметры, FLOPs и память
- 2.8.9 Абляции, профилирование и сопоставление при одинаковом бюджете
- 2.8.10 Сравнительная анатомия открытых моделей по отчётам, конфигурациям и коду

2.9. Графовые модели и структурированные знания

- 2.9.1 Граф и обход: вершины, рёбра, пути и связность
- 2.9.2 Вероятностные графические модели: факторизация распределения
- 2.9.3 Причинные графы: допущения о воздействиях
- 2.9.4 Онтологии и графы знаний: смысл отношений
- 2.9.5 Графовые эмбединги и GNN: обучение на связях
- 2.9.6 Граф вычислений, поиска и исполнения: разные назначения
- 2.9.7 Топологическое глубокое обучение и отношения высших порядков
- 2.9.8 Топологический анализ данных: комплексы, persistent homology и устойчивость к выбору масштаба
- 2.9.9 Zigzag persistence: изменение топологических признаков через слои и отличие от топологического обучения
- 2.9.10 Причинное обучение представлений: интервенционные данные, независимые механизмы и идентифицируемость

2.10. Генеративные модели

- 2.10.1 Авторегрессия: последовательное разложение распределения
- 2.10.2 VAE и латентные переменные: вероятностное кодирование
- 2.10.3 GAN: состязательное обучение генерации
- 2.10.4 Диффузия и оценка score: удаление шума
- 2.10.5 Нормализующие потоки и flow matching: преобразование распределений
- 2.10.6 Управляемость и оценка генерации: качество, разнообразие и условия
- 2.10.7 Probability Flow ODE и consistency models
- 2.10.8 Energy-based models: энергия, отрицательные примеры и обучение
- 2.10.9 JEPA: предсказание представлений, предотвращение коллапса и отличие от энергетических моделей
- 2.10.10 Scientific ML: физические ограничения, PINN, нейронные операторы и ошибки обобщения
- 2.10.11 Диффузионные языковые модели: дискретное зашумление, маскирование, восстановление и порядок генерации

- 2.10.12 Авторегрессия и диффузия текста: параллелизм, управляемость, RL и разнообразие при равном бюджете

2.11. Изображения, речь, аудио, музыка и видео

- 2.11.1 Язык и изображение: выравнивание представлений
- 2.11.2 VLM: восприятие изображения и работа с текстом
- 2.11.3 Речь: распознавание и синтез
- 2.11.4 Аудио и музыка: временная структура и управление
- 2.11.5 Видео: движение, согласованность и длительность
- 2.11.6 Документы: совместное понимание текста, таблиц и изображений
- 2.11.7 Мультимодальная оценка: согласованность и фактические ошибки
- 2.11.8 Мультимодальный переход: контрастивное выравнивание, инструкции, пространственное восприятие и действие
- 2.11.9 Поточные речевые агенты: смена реплик, перебивания, full-duplex, задержки и оценка диалога
- 2.11.10 Малоресурсные языки и межъязыковой перенос: данные, переключение языков и неоднородность качества

2.12. Нейронаука и модели обучения

- 2.12.1 Нейрон и синапс: сигнал и взаимодействие
- 2.12.2 Импульсные модели: динамика во времени
- 2.12.3 Синаптическая пластичность: механизмы изменения связи
- 2.12.4 Кодирование и декодирование: представление информации
- 2.12.5 Сети и популяции: динамика коллективной активности
- 2.12.6 Нейроморфные вычисления: перенос отдельных принципов
- 2.12.7 Сравнение с LLM: границы биологических аналогий
- 2.12.8 Методы измерения: запись активности, поведенческий эксперимент и вмешательство
- 2.12.9 Нормативные и механистические модели: что объясняется и чем проверяется
- 2.12.10 Обучение с наградой: связь нейронных сигналов и модели поведения
- 2.12.11 Спайковые сети, STDP и суррогатные градиенты
- 2.12.12 Free Energy Principle и активный вывод
- 2.12.13 Биогибридные вычисления и wetware

2.13. Биологическая память и вычислительные аналоги

- 2.13.1 Рабочая память: поддержание и обработка информации
- 2.13.2 Эпизодическая и семантическая память: разные виды содержания
- 2.13.3 Процедурная и недекларативная память: навыки и неосознанное обучение
- 2.13.4 Консолидация, воспроизведение и забывание: изменение памяти со временем
- 2.13.5 Ассоциативная память и сети Хопфилда: восстановление по части входа
- 2.13.6 Непрерывное обучение: интерференция старого и нового
- 2.13.7 Память агента: что является инженерной аналогией
- 2.13.8 Разделение и достраивание паттернов: различение похожих эпизодов и восстановление
- 2.13.9 Гиппокамп и неокортекс: взаимодополняющие системы обучения
- 2.13.10 Реконсолидация и ложные воспоминания: изменяемость сохранённого содержания
- 2.13.11 Динамические системы, аттракторы и устойчивость памяти

2.14. Модели решений и вероятностные интерфейсы: Jev и аналоги

- 2.14.1 Постановка: классификация, выбор, ранжирование и оценка состояния вместо генерации свободного текста
- 2.14.2 Вход и выход: наблюдаемое состояние, схема вопросов, допустимые значения и программный контракт
- 2.14.3 Jev (TypeSafe AI): пакет типизированных вопросов, вероятности, оценки и параллельные ответы
- 2.14.4 Choice, Noul и Score: смысл типов, исходы, шкалы и несопоставимые числовые величины
- 2.14.5 Структурный контракт и смысловая правильность: валидный тип не означает верного решения
- 2.14.6 Калибровка: reliability diagram, Brier score, log loss, ECE и сравнение с базовой частотой
- 2.14.7 Селективное предсказание: отказ, передача человеку и каскад моделей; риск при фиксированном покрытии
- 2.14.8 Сравнение с логистической регрессией, бустингом, энкодерными классификаторами и тонкими головами над эмбедингами
- 2.14.9 Сравнение с генеративным LLM при JSON Schema, log-prob классификацией и малыми специализированными LLM
- 2.14.10 Сравнение с моделью награды, reranker, safety-классификатором и LLM-судьей: разные цели и входы
- 2.14.11 Обучение вероятностных решений: разметка, proper scoring rules, RLCD как заявление разработчика и неполнота публичных сведений
- 2.14.12 Распределительный сдвиг и обновление модели: домены, ошибки схемы, калибровка после замены и аудит порогов
- 2.14.13 Встраивание в агента: выбор инструмента, маршрутизация, проверка, остановка и разделение правил от статистического суждения
- 2.14.14 Сравнение скорости и стоимости: общий вход, одинаковая схема, сопоставимое качество и полная цена процедуры
- 2.14.15 Jev как кейс молодого продукта: заявления поставщика, независимые исследования, доступность воспроизведения и неизвестная внутренняя архитектура

Блок 3. Данные, обучение, масштабирование и вычислительная инженерия

3.1. Данные для моделей

- 3.1.1 Сбор и происхождение: документирование корпуса
- 3.1.2 Очистка и дедупликация: качество и разнообразие
- 3.1.3 Смеси данных: язык, предмет и пропорции
- 3.1.4 Синтетические данные: полезность и риски самоповторения
- 3.1.5 Загрязнение тестов: скрытые утечки при оценивании
- 3.1.6 Версии, права и персональные данные: ограничения использования
- 3.1.7 Отбор данных и curriculum: ценность примера, покрытие редких случаев и порядок обучения

3.2. Предобучение и масштабирование

- 3.2.1 Авторегрессионные и маскированные цели: что именно оптимизируется
- 3.2.2 Подготовка последовательностей: упаковка и расписание
- 3.2.3 Баланс параметров, токенов и вычислений: законы масштабирования
- 3.2.4 Абляции: отделение причин улучшения
- 3.2.5 Продолженное предобучение: новые домены и языки
- 3.2.6 Контроль запуска: метрики, сбои и воспроизводимость
- 3.2.7 Chinchilla и compute-optimal обучение: предпосылки и ограничения законов масштабирования
- 3.2.8 Пределы синтетических корпусов: разнообразие, фильтрация и model collapse
- 3.2.9 Предобучение с извлечением: RETRO, совместная настройка, версия корпуса и отличие от прикладного RAG

3.3. Вычислительная инфраструктура обучения

- 3.3.1 Ускорители и память: размещение вычислений и данных
- 3.3.2 Числовая точность: компромиссы скорости и устойчивости
- 3.3.3 Параллелизм данных, модели и конвейера: разделение работы
- 3.3.4 Коммуникации и шардирование: узкие места
- 3.3.5 Контрольные точки и восстановление: продолжение после сбоя
- 3.3.6 Профилирование и энергия: измерение полного ресурса
- 3.3.7 Tensor, pipeline, data, expert и context parallelism
- 3.3.8 ZeRO, FSDP и шардирование параметров, градиентов и состояния оптимизатора
- 3.3.9 Activation checkpointing, накопление градиентов и overlap коммуникаций
- 3.3.10 Компиляторы и ядра: слияние операций, IO-сложность, roofline и проверка численной эквивалентности

3.4. Адаптация и дообучение

- 3.4.1 SFT и instruction tuning: обучение требуемому поведению
- 3.4.2 Полное дообучение и PEFT: какие параметры меняются
- 3.4.3 LoRA и адаптеры: низкоранговое обновление
- 3.4.4 Prompt/prefix tuning: обучаемая входная часть
- 3.4.5 Забывание и регрессии: проверка сохранённых способностей
- 3.4.6 Выбор между дообучением и извлечением: постановка задачи

- 3.4.7 Что именно изменяется при адаптации. Сопоставить заморозку слоёв, линейную пробу, голову, адаптеры и LoRA по обучаемым параметрам и роли представлений
- 3.4.8 Continual learning: replay, регуляризация, изоляция параметров и проверка забывания
- 3.4.9 Test-time adaptation и meta-learning: что обновляется, утечки и устойчивость онлайн-адаптации

3.5. Дистилляция моделей и данных

- 3.5.1 Учитель и ученик: мягкие цели и температура
- 3.5.2 Ответы, признаки и распределения: варианты сигнала
- 3.5.3 Последовательности и рассуждения: передача поведения
- 3.5.4 Ранжировщики и агенты: прикладные формы переноса
- 3.5.5 Самодистилляция: обучение от собственных сигналов
- 3.5.6 Дистилляция датасета: оптимизация обучающих примеров
- 3.5.7 Проверка: сохранение качества и независимость теста
- 3.5.8 Offline, on-policy и self-distillation

3.6. Сжатие, разреженность и объединение

- 3.6.1 Квантизация: числовое представление весов и активаций
- 3.6.2 Pruning: удаление элементов и структур
- 3.6.3 Разреженность: достижимая экономия на оборудовании
- 3.6.4 Факторизация и merging: другие преобразования весов
- 3.6.5 Сочетание методов: накопление ошибок
- 3.6.6 Проверка регрессий: задачи, чувствительные к сжатию
- 3.6.7 Lottery Ticket Hypothesis и роль инициализации

3.7. Декодирование и системы инференса

- 3.7.1 Семплирование, температура и отсечения: распределение выходов
- 3.7.2 Prefill и decode: разные режимы нагрузки
- 3.7.3 KV-cache: повторное использование промежуточных данных
- 3.7.4 Batching и управление памятью: обслуживание запросов
- 3.7.5 FlashAttention и speculative decoding: ускорение
- 3.7.6 Ограниченный вывод: соблюдение структуры
- 3.7.7 Задержка, стоимость и пропускная способность: совместная оценка
- 3.7.8 PagedAttention и управление страницами KV-cache: фрагментация и совместное использование
- 3.7.9 Разделение prefill и decode: DistServe, передача состояния и планирование нагрузки
- 3.7.10 Компиляция процесса генерации: SGLang, повторное использование префиксов и структурированный вывод
- 3.7.11 Goodput и SLO: TTFT, TPOT, p50/p95, очереди и число запросов с выполненными требованиями

Блок 4. Постобучение, рассуждение и проверка решений

4.1. Подкрепление, предпочтения и согласование

- 4.1.1 Политика, ценность и уравнение Беллмана: основы RL
- 4.1.2 Градиент политики: оптимизация поведения
- 4.1.3 Модель вознаграждения: получение сигнала из сравнений
- 4.1.4 RLHF и RLAIIF: источники обратной связи
- 4.1.5 DPO и родственные цели: обучение на предпочтениях
- 4.1.6 Подмена цели и поддакивание: ограничения выбранной награды
- 4.1.7 Математика предпочтений и модель вознаграждения. Bradley-Terry, разность оценок, правдоподобие, log-sigmoid; связь формулы с реализацией и данными сравнений
- 4.1.8 PPO: ограничение обновления политики и роль KL-регуляризации
- 4.1.9 Offline и online предпочтения: сбор, шум и распределительный сдвиг
- 4.1.10 Constitutional AI, согласование целей и выбор принципов
- 4.1.11 Exploration и off-policy обучение: actor-critic, value-based методы и оценка политики по журналам
- 4.1.12 Offline RL, model-based RL и обучение по демонстрациям: покрытие действий и распределительный сдвиг

4.2. Обучение рассуждению и вычисления при решении

- 4.2.1 Проверяемая награда и RLVR: постановка задач
- 4.2.2 GRPO и развитие оптимизации: предпосылки алгоритма
- 4.2.3 Контроль процесса и результата: где измерять качество
- 4.2.4 Верификаторы и поиск кандидатов: отбор решения
- 4.2.5 Вычисления при решении: поиск, распределение бюджета, стоимость и эффективность
- 4.2.6 Верность объяснения: почему текст не раскрывает механизм автоматически
- 4.2.7 Открытые рецепты постобучения. Сквозной разбор SFT, предпочтений и проверяемой награды на открытом проекте; отдельно отслеживать данные, оценку и абляции этапов
- 4.2.8 Оценка рассуждения до и после изменения метода
- 4.2.9 PRM и итоговая награда: разметка шагов, credit assignment и ошибки верификатора
- 4.2.10 MCTS, поиск в ширину и глубину, beam search и распределение бюджета
- 4.2.11 Self-consistency, best-of-N и адаптивное время решения
- 4.2.12 Обучение использованию инструментов и многошаговым агентным траекториям
- 4.2.13 Эффект RLVR: pass@1, pass@k, поиск новых решений и перераспределение вероятностей
- 4.2.14 Формальное доказательство и программные верификаторы: Lean, proof search, спецификация и корректность проверяющего

Блок 5. Внутренние механизмы, надёжность и безопасность

5.1. Знания внутри модели и интерпретируемость

- 5.1.1 Запоминание и обобщение: разные источники ответа
- 5.1.2 Обучение в контексте: изменение поведения без обновления весов
- 5.1.3 Пробы и причинные вмешательства: границы наблюдения
- 5.1.4 Цепи вычислений, superposition и SAE: исследовательские подходы
- 5.1.5 Редактирование знаний: ROME, AlphaEdit, последовательные правки, локальность и многошаговые следствия
- 5.1.6 Объяснение модели: ограничения уверенного описания механизма
- 5.1.7 Induction heads и circuit discovery: поиск реализованных алгоритмов
- 5.1.8 Activation patching, path patching и causal tracing
- 5.1.9 SAE: словарь признаков, разреженность, полнота и проверка вмешательствами
- 5.1.10 Аттракторы и динамика представлений: наблюдение и доказательство механизма
- 5.1.11 Межмодельный перенос признаков: совпадение геометрии, причинный эффект и перенос способности как разные проверки

5.2. Оценка моделей и представлений

- 5.2.1 Конструкция бенчмарка: цель и выбор примеров
- 5.2.2 Загрязнение, переобучение и смена версий: надёжность сравнения
- 5.2.3 Калибровка и неопределённость: качество уверенности, отказ и перенос между распределениями
- 5.2.4 Эмбединги и ранжировщики: отдельные оценочные задачи
- 5.2.5 Судьи-модели: смещения и человеческая проверка
- 5.2.6 Повторяемость и статистика: различие сигнала и шума
- 5.2.7 Проверка оценщика и перенос качества оценки. Отделить качество модели награды, выбор кандидата и итог обучения политики; разобрать RewardBench и RewardBench 2
- 5.2.8 Разнообразие генераций: семантическое покрытие, коррелированные ошибки и независимость кандидатов
- 5.2.9 Conformal generation и selective prediction: покрытие множества, полезность ответа и цена отказа

5.3. Надёжность, безопасность и приватность

- 5.3.1 Галлюцинации и необоснованная уверенность: классификация ошибок
- 5.3.2 Поддакивание: зависимость вывода от позиции пользователя
- 5.3.3 Извлечение обучающих данных: приватность параметров
- 5.3.4 Устойчивость инструкций и внешнего контекста: границы доверия
- 5.3.5 Предвзятость и распределение ошибок: социальный контекст оценки
- 5.3.6 Отказ и неопределённость: проверяемость ограничения ответа
- 5.3.7 Weak-to-strong generalization и масштабируемый надзор
- 5.3.8 Масштабируемый надзор, reward hacking и specification gaming
- 5.3.9 Обман и скрытые цели: постановки экспериментов и границы свидетельств
- 5.3.10 Удаление данных, machine unlearning и проверка остаточной информации
- 5.3.11 Запоминание и приватность: membership inference, verbatim extraction и модели угроз

- 5.3.12 Сохранение защитного поведения после дообучения: глубина отказа, атаки и регрессии
- 5.3.13 Differential privacy: соседние датасеты, бюджет приватности и компромисс с качеством

5.4. Фронтир и пределы установленного знания

- 5.4.1 Длительное рассуждение и агентность: устойчивость последовательных действий
- 5.4.2 Непрерывное обучение и память: адаптация без потери знаний
- 5.4.3 Композиционность и перенос: новые сочетания задач
- 5.4.4 Модели мира и причинность: проверка предсказательной силы
- 5.4.5 Научные открытия: независимое подтверждение гипотез
- 5.4.6 Оценка новых систем: устаревание тестов и воспроизводимость

Блок 6. Профессиональное использование, знания и агентные системы

6.1. Сотрудничество человека и модели

Основы использования

- 6.1.1 Постановка задачи: цель, ограничения и ожидаемый результат
- 6.1.2 Уточнение неопределённости: какие сведения действительно нужны
- 6.1.3 Делегирование: границы самостоятельности
- 6.1.4 Возможности среды: модель, интерфейс, файлы, поиск, вычисления и реально доступные инструменты
- 6.1.5 Выбор режима: ответ, поиск, исследование, редактирование или исполнение; критерии выбора
- 6.1.6 Разовый запрос и проект: какие решения и материалы должны пережить диалог

Повторяемая профессиональная работа

- 6.1.7 Обратная связь: исправление причины ошибки
- 6.1.8 Приёмка: независимые критерии готовности
- 6.1.9 Паспорт задачи: входы, результат, критерии, допустимые действия и условия уточнения
- 6.1.10 Рабочий диалог: исправление требований, промежуточная приёмка и сохранение решений

Проектирование и диагностика

- 6.1.11 Человеческая оценка и взаимодействие: доверие, automation bias, когнитивная нагрузка и совместная работа
- 6.1.12 Диагностика неудачи: нехватка знаний, контекста, инструмента, полномочий или проверки
- 6.1.13 Классическая инженерия и LLM: что наследуется, что изменяется и чем измеряется новизна

Фронтир и сравнительные эксперименты

- 6.1.14 Адаптивное делегирование: ценность участия человека, цена уточнения и измерение продуктивности

6.2. Промпт-инжиниринг: постановка, проверка и оптимизация задач

Основы использования

- 6.2.1 Инструкция и контекст: отделение цели от данных
- 6.2.2 Примеры: чему учит few-shot формат
- 6.2.3 Разметка: границы фрагментов и XML-теги
- 6.2.4 Анатомия промпта: цель, входные данные, требования, аудитория и формат результата
- 6.2.5 Роли сообщений и приоритет инструкций: различия интерфейсов и границы управления пользователем
- 6.2.6 Zero-shot, few-shot и контрпримеры: подбор репрезентативных демонстраций

Повторяемая профессиональная работа

- 6.2.7 Ограничения и схемы: управление формой ответа
- 6.2.8 Негативные случаи: двусмысленность и противоречия
- 6.2.9 Шаблоны задач: извлечение, сравнение, проверка утверждения, редактурa, код и расчёт
- 6.2.10 Работа с неопределённостью: запрос недостающих данных, отказ от догадок и разделение факта с выводом
- 6.2.11 Мультимодальный промпт: связь текста с областью изображения, страницей, таблицей и временным фрагментом

Проектирование и диагностика

- 6.2.12 Тестирование промпта: набор задач и устойчивость
- 6.2.13 Промпт как версия эксперимента: переменные, набор случаев, абляции и журнал изменений
- 6.2.14 Устойчивость к перефразированию, порядку примеров, языку и смене модели
- 6.2.15 Запрос объяснения и проверка решения: наблюдаемая аргументация не равна внутреннему вычислению

Фронтир и сравнительные эксперименты

- 6.2.16 Программирование и оптимизация LLM-процессов. DSPy: сигнатуры, модули, демонстрации и оптимизатор; выделить обучающие и проверочные примеры и сравнить с ручным промптингом
- 6.2.17 Автоматическая оптимизация: DSPy, MIPRO и GEPA, отдельные обучающие и тестовые задачи
- 6.2.18 Совместная оптимизация инструкций и демонстраций по трассам ошибок
- 6.2.19 Переобучение на оценщике и перенос промпта: новые задачи, версии и затраты поиска

6.3. Цепи, деревья и графы решения

Основы использования

- 6.3.1 Декомпозиция: независимые и связанные части задачи
- 6.3.2 Одно действие, цепочка и цикл: когда декомпозиция помогает и когда создаёт лишнюю работу

Повторяемая профессиональная работа

- 6.3.3 ReAct: чередование действия и наблюдения
- 6.3.4 Несколько кандидатов: отбор и согласованность
- 6.3.5 Самокритика: условия полезности обратной связи
- 6.3.6 Остановка: отсутствие прогресса и бюджет
- 6.3.7 Prompt chaining, маршрутизация и map-reduce: контракты промежуточных результатов
- 6.3.8 Plan-and-execute: проверяемый план, исполнение и пересмотр после наблюдения

Проектирование и диагностика

- 6.3.9 Tree of Thoughts: ветвление поиска
- 6.3.10 Graph of Thoughts: объединение и повторное использование результатов
- 6.3.11 Параллельные ветки и зависимости: слияние результатов, дубли и противоречия

- 6.3.12 Evaluator–optimizer: независимый критерий улучшения и защита от бесконечной правки

Фронтир и сравнительные эксперименты

- 6.3.13 Адаптивный выбор глубины поиска и числа кандидатов при фиксированном бюджете
- 6.3.14 Оптимизация графа процесса: какие узлы менять, как сравнивать и предотвращать утечки

6.4. Контекст-инжиниринг: данные, состояние и непрерывность работы

Основы использования

- 6.4.1 Отбор информации: релевантность и приоритет
- 6.4.2 Состав контекста: инструкции, история, документы, результаты инструментов и рабочее состояние
- 6.4.3 Контекстное окно и память проекта: доступность информации и фактическая загрузка в запрос

Повторяемая профессиональная работа

- 6.4.4 Сборка контекста: инструкции, данные и свидетельства
- 6.4.5 Длинный контекст: порядок и положение фрагментов
- 6.4.6 Постепенное раскрытие: загрузка информации по потребности
- 6.4.7 Пакет контекста: паспорт задачи, карта источников, решения, открытые вопросы и следующий шаг
- 6.4.8 Иерархия источников: актуальная версия, первоисточник, производная заметка и конфликт сведений
- 6.4.9 Длинные файлы: обзор структуры, адресная загрузка и возврат к точному фрагменту

Проектирование и диагностика

- 6.4.10 Сжатие: потери и проверка сохранности решений
- 6.4.11 Передача между сессиями: восстановление состояния
- 6.4.12 Контекстный бюджет: ценность фрагмента, дубли, порядок, цитаты и объём результатов инструментов
- 6.4.13 Compression и handoff: контроль потери ограничений, незавершённых задач и отрицательных результатов
- 6.4.14 Кэширование префикса и повторное использование вычислений: отличие от памяти фактов
- 6.4.15 Недоверенные документы: разделение данных и инструкций, происхождение и защита границ
- 6.4.16 Исходник, производный синтез и контекст запроса: происхождение данных и инвалидирование устаревшей информации

Фронтир и сравнительные эксперименты

- 6.4.17 Рекурсивная обработка контекста: внешняя среда, программный доступ и Recursive Language Models
- 6.4.18 Обучаемый отбор, сжатие и обновление контекста: награда, перенос и стоимость
- 6.4.19 Сравнение длинного контекста, RAG, памяти и рекурсивного доступа на одинаковых задачах

6.5. Подготовка документов

- 6.5.1 PDF и OCR: текстовый слой, сканы и качество распознавания
- 6.5.2 Структура: заголовки, списки, таблицы и изображения
- 6.5.3 Сегментация: границы документа, раздела и фрагмента
- 6.5.4 Метаданные: автор, дата, версия и права
- 6.5.5 Якоря: страница, раздел, таблица и ячейка
- 6.5.6 Проверка обработки: пропуски, смешанные колонки и повторы
- 6.5.7 Извлечение по схеме и доказательство каждого поля
- 6.5.8 Научные документы: OCR формул, сносок, библиографии и сверка структуры с изображением страницы
- 6.5.9 Excel как источник вычислений: листы, формулы, диапазоны, типы и происхождение результата

6.6. Индексы, поиск и ранжирование

- 6.6.1 BM25 и инвертированный индекс: лексическое соответствие
- 6.6.2 Точный векторный поиск: исходная точка сравнения
- 6.6.3 HNSW: граф навигации по векторному пространству
- 6.6.4 IVF, PQ и дисковый поиск: разные компромиссы индекса
- 6.6.5 Гибридный поиск и слияние: объединение сигналов
- 6.6.6 Переранжирование и late interaction: прямое сравнение кандидатов
- 6.6.7 Фильтрация и обновление: ограничения корпуса
- 6.6.8 Recall, nDCG и задержка: оценка качества и затрат
- 6.6.9 Learning-to-rank и обратная связь поиска
- 6.6.10 Обучение и адаптация retrieval-эмбедингов на предметном корпусе
- 6.6.11 Выбор векторной БД: recall, latency, фильтры, обновления и стоимость
- 6.6.12 Обучаемый разреженный поиск: SPLADE, расширение запроса и сопоставление с BM25
- 6.6.13 Индексы как часть БД: фильтры, селективность, план запроса, конкурентные обновления и согласованность
- 6.6.14 Обратная связь ранжирования: смещения кликов, контрфактуальная оценка и онлайн-эксперимент

6.7. RAG от источника до проверяемого ответа

- 6.7.1 Документ и фрагмент: подходящая единица поиска
- 6.7.2 Запрос: интерпретация и маршрутизация
- 6.7.3 Извлечение и переранжирование: состав доказательств
- 6.7.4 Сборка контекста: полнота и отсутствие лишнего
- 6.7.5 Ответ и цитаты: привязка утверждений к источникам
- 6.7.6 Недостаток сведений: отказ и уточнение
- 6.7.7 Обновление: согласованность базы и ответа

6.8. Адаптивный, графовый и агентный RAG

- 6.8.1 Разложение запроса и multi-hop: последовательное получение свидетельств
- 6.8.2 Self-RAG: поиск и оценка опоры ответа
- 6.8.3 RAPTOR: иерархические представления документов
- 6.8.4 GraphRAG: сущности, сообщества и обзор корпуса
- 6.8.5 Агентный поиск: выбор следующего источника
- 6.8.6 Таблицы и мультимодальность: извлечение разных типов данных

- 6.8.7 Длинный контекст и RAG: сравнение на одинаковых задачах
- 6.8.8 Corrective RAG, проверка извлечения и повторный поиск
- 6.8.9 Text-to-SQL, структурированные запросы и сочетание с документами
- 6.8.10 Сравнительный маршрут по ранее собранным SAG, RouteRAG, RRPO, RAGSieve, QV-PIC и RAG in the Wild: уточнение публикаций и проверка механизмов

6.9. Графы знаний на практике

- 6.9.1 Сущности и идентичности: объединение разных упоминаний
- 6.9.2 Онтология: какие отношения разрешены
- 6.9.3 Извлечение связей: доказательство каждого утверждения
- 6.9.4 Время и версии: изменение истинности
- 6.9.5 Противоречия: хранение конкурирующих сведений
- 6.9.6 Обход и запрос: выбор связанного контекста
- 6.9.7 Сочетание с текстом: возврат к первоисточнику

6.10. RAG и корпоративные базы знаний

Основы использования

- 6.10.1 Управление знаниями: владельцы, таксономии и организационная память
- 6.10.2 Источники и загрузка: поступление и качество данных
- 6.10.3 LLM Wiki: неизменные источники, производные страницы и правила обслуживания

Повторяемая профессиональная работа

- 6.10.4 Происхождение и версии: авторитетный документ и актуальность
- 6.10.5 Хранение и поиск: гибридные индексы и ранжирование
- 6.10.6 Графовый и агентный RAG: сложные вопросы
- 6.10.7 Проверяемые ответы: точные цитаты и отказ
- 6.10.8 Доступ и изоляция: полномочия во всём процессе
- 6.10.9 Редакционный цикл: согласование, исправление и архивирование
- 6.10.10 Оценка и эксплуатация: качество, восстановление и стоимость
- 6.10.11 Агенты поверх базы: поиск, действия и запись новых знаний
- 6.10.12 Выбор технологии: локальное размещение, внешние сервисы и переносимость
- 6.10.13 Ключевая метрика: качество завершённой рабочей задачи при заданных ограничениях
- 6.10.14 Агентные документные процессы
- 6.10.15 Приём источника, поиск по wiki и проверка связности: ingest, query и lint

Проектирование и диагностика

- 6.10.16 Коннекторы и инкрементальная синхронизация: CDC, удаления и повторная индексация
- 6.10.17 ACL на уровне документа и фрагмента; фильтрация до и после поиска
- 6.10.18 Мультитенантность, отзыв доступа и удаление производных представлений
- 6.10.19 Согласованность версии исходника, эмбединга, индекса и кэша
- 6.10.20 SLO, миграция индексов, резервирование и аварийное восстановление
- 6.10.21 Выбор RAG, длинного контекста, дообучения или их комбинации
- 6.10.22 Совместная редакция корпуса: читатель и редактор, блокировки, heartbeat, конфликтные копии и журнал изменений

- 6.10.23 Производная база знаний: зависимости, пересборка, версии, откат и устранение ошибочного синтеза

Фронтир и сравнительные эксперименты

- 6.10.24 Wiki плюс RAG: сравнение предварительного синтеза и поиска по исходникам на новых и изменённых данных

6.11. Структурированные результаты и контракты

Основы использования

- 6.11.1 Схемы и типы: структура данных
- 6.11.2 Неизвестные значения и ошибки: честное представление состояния
- 6.11.3 Текст, таблица, JSON и файл: выбор формы результата под дальнейшее использование

Повторяемая профессиональная работа

- 6.11.4 Предусловия и постусловия: смысл успешного действия
- 6.11.5 Схемы с источниками: значение, единица измерения, неопределённость и доказательство поля
- 6.11.6 Вызов инструмента и успешный результат: проверка ответа сервиса и фактического изменения

Проектирование и диагностика

- 6.11.7 Валидация: структура, семантика и полномочия
- 6.11.8 Совместимость и версии: изменение контракта
- 6.11.9 Ошибки схемы и исправление: ограниченные повторы, несовместимые версии и журнал причин

Фронтир и сравнительные эксперименты

- 6.11.10 Типизированная композиция инструментов и формально проверяемые ограничения процесса

6.12. Инструменты, API и MCP

Основы использования

- 6.12.1 Описание инструмента: вход, результат и побочные эффекты
- 6.12.2 MCP: роли, сообщения и возможности
- 6.12.3 Ресурсы и инструменты: разные формы доступа
- 6.12.4 Подключение готового MCP: выбор сервера, настройка клиента и проверка доступных возможностей
- 6.12.5 Host, client и server: кто выбирает действие, где оно выполняется и что получает модель
- 6.12.6 Tools, resources и prompts: вызов действия, чтение данных и получение шаблона

Повторяемая профессиональная работа

- 6.12.7 API и вызов функций: выполнение запроса
- 6.12.8 Авторизация и изоляция: ограничения действия

- 6.12.9 Локальное и удалённое подключение: среда исполнения, транспорт и доступ из разных клиентов
- 6.12.10 Сеанс работы: обнаружить возможность, прочитать контракт, вызвать и проверить результат
- 6.12.11 Матрица совместимости клиента: версия протокола, расширения и неподдерживаемые возможности
- 6.12.12 Чтение и запись: предварительный просмотр, подтверждение значимых действий и аудит

Проектирование и диагностика

- 6.12.13 Асинхронность, отмена и ошибки: управление длительной работой
- 6.12.14 Собственный сервер: тестирование контрактов
- 6.12.15 Версии MCP, согласование возможностей и модель взаимодействия клиента с сервером
- 6.12.16 OAuth, удалённые серверы, доверие и минимальные полномочия
- 6.12.17 Браузерные и компьютерные агенты: DOM, скриншоты, grounding действий и проверка эффекта
- 6.12.18 Дизайн инструмента: размер операции, именование, параметры, пагинация и полезная ошибка
- 6.12.19 MCP Inspector и интеграционные проверки: воспроизведение вызова вне модели
- 6.12.20 OAuth и scopes: истечение доступа, делегирование и изоляция учётных данных
- 6.12.21 Версии MCP: сравнение жизненного цикла и согласования возможностей; не смешивать требования редакций

Фронтир и сравнительные эксперименты

- 6.12.22 Динамическое обнаружение инструментов: поиск по каталогу, отложенная загрузка и полнота выбора
- 6.12.23 Программная композиция вызовов: code execution с MCP, сокращение обмена и контроль среды
- 6.12.24 Опциональные расширения MCP: длительные задачи, интерактивные приложения и доставка навыков; поддержка по версиям
- 6.12.25 Оценка MCP-процесса: корректность выбранного инструмента, аргументов, результата и полномочий

6.13. Навыки, плагины и hooks: использование и проектирование

Основы использования

- 6.13.1 Навык и процедура: повторное использование инструкции
- 6.13.2 Плагин: состав и зависимости возможностей
- 6.13.3 Промпт, инструкция проекта, навык, плагин и сервер: назначение и границы каждого элемента
- 6.13.4 Использование готового навыка: выбор, явный вызов, входные материалы и проверка результата
- 6.13.5 Установка плагина: состав, требуемая среда, доступы, включение и отключение

Повторяемая профессиональная работа

- 6.13.6 Hooks и события: моменты автоматической проверки
- 6.13.7 Выбор и загрузка навыка: контекст по потребности
- 6.13.8 SKILL.md: назначение, условия запуска, входы, шаги, исключения и критерии завершения

- 6.13.9 Описание навыка: пропущенный и ложный запуск, конкуренция похожих описаний
- 6.13.10 References, scripts и assets: отделение обязательной инструкции от загружаемых материалов
- 6.13.11 Доведение процедуры до навыка: успешный ручной процесс, шаблон, примеры и тестовые случаи
- 6.13.12 Плагин как пакет: манифест, пространства имён, навыки, инструменты, агенты и зависимости

Проектирование и диагностика

- 6.13.13 Версии и конфликты: совместимость инструкций
- 6.13.14 Проверка навыка: регрессии и отрицательные примеры
- 6.13.15 Hooks: события до и после действий, синхронная проверка и фоновое наблюдение
- 6.13.16 Надёжность обработчиков: повтор события, рекурсия, блокировка завершения, тайм-аут и ошибка
- 6.13.17 Приоритет и композиция инструкций: пользователь, проект, навык и конфликт пакетов
- 6.13.18 Версия, выпуск, обновление и откат плагина; аудит скриптов и происхождения зависимостей
- 6.13.19 Проверка навыка: запуск на новых случаях, устойчивость к отсутствующим входам и смене модели
- 6.13.20 Навык как модуль процедуры: контракт применения, зависимости и граница между инструкцией и исполняемой проверкой

Фронтир и сравнительные эксперименты

- 6.13.21 Извлечение навыков из траекторий: обобщение опыта, верификация и контролируемое принятие
- 6.13.22 Автоматическая оптимизация библиотеки навыков: выбор, дубли, композиция и перенос
- 6.13.23 Переносимость между клиентами: общий формат навыка, специфичные поля и фактическая семантика исполнения
- 6.13.24 Сравнение инструкции, навыка со скриптом и дообучения: качество, затраты и сопровождение

6.14. Графы задач и конечные автоматы

Основы использования

- 6.14.1 Чек-лист в инструкции и исполняемый автомат: где реально контролируется порядок
- 6.14.2 Граф исполнения, граф данных и граф знаний: разные вершины, рёбра и значения перехода

Повторяемая профессиональная работа

- 6.14.3 DAG: зависимости между задачами
- 6.14.4 FSM: состояния и разрешённые переходы
- 6.14.5 Условия перехода: результаты внешней проверки
- 6.14.6 Шаги с входом, выходом и критерием перехода: запрет перескакивания проверяется состоянием
- 6.14.7 DAG и циклический workflow: обратные рёбра, повторные попытки и зависимость задач

Проектирование и диагностика

- 6.14.8 Statecharts: иерархия и параллельность
- 6.14.9 Миграция процесса: изменения во время длительной работы
- 6.14.10 Исполнение: сохранение и восстановление истории
- 6.14.11 Иерархическое планирование HTN и дерева поведения
- 6.14.12 Approval gate и human-in-the-loop: пауза, решение человека, возобновление и журнал
- 6.14.13 Ограничения естественного языка: внешняя проверка инвариантов и фактического действия
- 6.14.14 BPMN и сети Петри: события, токены, синхронизация, блокировки и сравнение со statecharts

Фронтир и сравнительные эксперименты

- 6.14.15 Инварианты, достижимость, safety и liveness контроллера
- 6.14.16 Синтез и проверка процесса из спецификации: ошибки автоматической формализации
- 6.14.17 Проверка модели процесса: достижимость, взаимная блокировка и разрыв между диаграммой и исполнителем

6.15. Циклы работы агента: выполнение, остановка и восстановление

Основы использования

- 6.15.1 Наблюдение, действие и проверка: цикл управления
- 6.15.2 Loop: условие входа, наблюдение, действие, проверка, обновление состояния и выход
- 6.15.3 Один вызов модели, цикл агента и повтор по расписанию: разные механизмы

Повторяемая профессиональная работа

- 6.15.4 Планирование и перепланирование: реакция на новые сведения
- 6.15.5 Тайм-ауты и повторы: обработка отказов
- 6.15.6 Бюджет и остановка: обнаружение отсутствия прогресса
- 6.15.7 Внутренний цикл задачи и внешний цикл улучшения: результат работы против изменения процедуры
- 6.15.8 План → действие → проверка → исправление: цикл на одном документе или программной задаче
- 6.15.9 Критерии остановки: успех, блокировка, исчерпание бюджета, отмена и отсутствие прогресса
- 6.15.10 Цикл обратной связи и while: состояние среды, наблюдаемость, задержка и критерий качества управления

Проектирование и диагностика

- 6.15.11 Идемпотентность: повтор без удвоения побочного эффекта
- 6.15.12 Откат и контрольные точки: возврат к известному состоянию
- 6.15.13 Retry, repair и replan: повтор запроса, исправление результата и смена стратегии
- 6.15.14 Бесконечная самокритика и повтор ошибки: детектор стагнации, внешний сигнал и эскалация
- 6.15.15 Восстановление после обрыва: checkpoint, replay и защита от повторного внешнего действия

- 6.15.16 Стоп и событийные триггеры: пропущенные запуски, перекрытия, дедупликация и доставка результата
- 6.15.17 Таксономия отказов: транспортный сбой, нарушение контракта, фактическая ошибка и ложное завершение

Фронтир и сравнительные эксперименты

- 6.15.18 Рекурсивные и вложенные циклы: общий бюджет, глубина, зависимости и отмена дочерних задач
- 6.15.19 Обучение условиям остановки и перепланирования: сравнение с фиксированными правилами
- 6.15.20 Самоизменяющийся процесс: отдельная проверка новой версии, отложенные задачи и откат

6.16. Память и состояние

Основы использования

- 6.16.1 Рабочая и долговременная память: разные сроки использования
- 6.16.2 Эпизоды, факты и процедуры: содержание записи
- 6.16.3 Память пользователя, память проекта и состояние задачи: владелец, срок жизни и доступ

Повторяемая профессиональная работа

- 6.16.4 Запись и консолидация: выбор сохраняемой информации
- 6.16.5 Извлечение и забывание: полезность и стоимость
- 6.16.6 Состояние задачи: переходы, версии и восстановление
- 6.16.7 Журнал решений и ошибок: что сохранять, когда читать и как исправлять запись

Проектирование и диагностика

- 6.16.8 Исправление и происхождение: защита от ложных воспоминаний
- 6.16.9 Оценка памяти: нужное найдено, ошибочное не использовано
- 6.16.10 Память нескольких пользователей: разграничение и разрешение противоречий
- 6.16.11 Переоценка процедурных навыков после изменения среды
- 6.16.12 Конфликт памяти с новым источником: время, приоритет, происхождение и удаление производных записей

Фронтир и сравнительные эксперименты

- 6.16.13 Консолидация и забывание памяти агента: сроки, оценка полезности, удаление и восстановление происхождения
- 6.16.14 Память опыта и процедур: перенос навыка на новую задачу без закрепления ошибки

6.17. Архитектура собственного агента

Основы использования

- 6.17.1 Готовый агент, workflow и собственный harness: выбор сложности под задачу

Повторяемая профессиональная работа

- 6.17.2 Контроллер: выбор следующего шага
- 6.17.3 Модель и инструменты: распределение вычислений
- 6.17.4 Планировщик и исполнитель: подготовка и действие
- 6.17.5 Минимальная система и расширение: сравнение архитектур
- 6.17.6 Настройка среды: рабочие файлы, исполняемые инструменты, проверки и журнал прогресса

Проектирование и диагностика

- 6.17.7 Память и хранилища: устойчивое состояние
- 6.17.8 Верификатор: независимые основания приёмки
- 6.17.9 Прототип и эксплуатация: новые требования надёжности
- 6.17.10 Разделение модели и контроллера: правила исполнения, наблюдение и замена исполнителя

Фронтир и сравнительные эксперименты

- 6.17.11 Автоматическое проектирование harness: оптимизация компонентов на обучающем наборе и независимая проверка
- 6.17.12 Вероятностный слой решений: пороги, отказ и эскалация при выборе следующего шага агента; Jev как один из возможных исполнителей

6.18. Базы данных и среда исполнения

Основы использования

- 6.18.1 Реляционные, документные, векторные и графовые базы: назначение
- 6.18.2 Workflow-движок и агент: исполнитель переходов отдельно от модельного выбора

Повторяемая профессиональная работа

- 6.18.3 Очереди и фоновые исполнители: длительные задачи
- 6.18.4 События и транзакции: согласованность состояния
- 6.18.5 Конкурентный доступ и блокировки: работа нескольких исполнителей
- 6.18.6 Логи, метрики и трассы: наблюдение за исполнением
- 6.18.7 Airflow и Temporal: зависимости задач и долговечное исполнение как разные исходные задачи

Проектирование и диагностика

- 6.18.8 Изолированная среда и зависимости: воспроизводимость
- 6.18.9 Резервирование и восстановление: сохранность прогресса
- 6.18.10 Изоляция транзакций, event sourcing и transactional outbox
- 6.18.11 Семантика доставки, дедупликация действий и fencing tokens
- 6.18.12 Планировщик исполнения: квоты, backpressure, fairness, отмена и управление перегрузкой
- 6.18.13 История событий и replay: запись ответа модели, внешние действия и детерминированная часть контроллера

Фронтир и сравнительные эксперименты

- 6.18.14 Гарантии исполнения: повтор доставки, идемпотентный эффект и границы обещания exactly-once

6.19. Многоагентные системы

Основы использования

- 6.19.1 Делегирование и специализация: независимые задачи
- 6.19.2 Выбор одного агента или команды: независимые задачи и достаточность общей памяти
- 6.19.3 Актор и интеллектуальный агент: сообщения и локальное состояние против целей и планирования

Повторяемая профессиональная работа

- 6.19.4 Обмен результатами: минимальный достаточный контекст
- 6.19.5 Критик и исполнитель: независимость оценки
- 6.19.6 Поручение исполнителю: границы задачи, ожидаемый артефакт и основания результата

Проектирование и диагностика

- 6.19.7 Общие ресурсы: конфликты и согласование
- 6.19.8 Стоимость координации: когда агенты мешают
- 6.19.9 Сквозная оценка: сравнение с одним агентом
- 6.19.10 Независимость критиков, коррелированные ошибки и экспериментальные сравнения
- 6.19.11 Каналы коммуникации: текст, структурированные сообщения, эмбединги, активации и KV-cache
- 6.19.12 Изоляция контекста и слияние работы: потеря информации, конфликты файлов и проверка зависимостей
- 6.19.13 BDI, обязательства и протоколы взаимодействия: основания теории агентов и применение к LLM

Фронтир и сравнительные эксперименты

- 6.19.14 Совместное обучение: mutual distillation, self-play, кооперативное RL и обучаемая коммуникация
- 6.19.15 Обучаемые мосты Cache-to-Cache: совместимость, качество источника, память и сетевой обмен
- 6.19.16 Масштабирование коммуникации: попарные адаптеры, общий интерфейс и перенос на новую модель
- 6.19.17 Диверсификация команды: корреляция ошибок, разнообразие гипотез и сравнение при равном бюджете
- 6.19.18 Адаптивное формирование команды: специализация, бюджет, остановка ветвей и воспроизводимость

6.20. Агент как участник команды

Основы использования

- 6.20.1 Асинхронные поручения: работа вне текущего диалога
- 6.20.2 Передача агенту длительной задачи: статус, канал результата и условия вмешательства

Повторяемая профессиональная работа

- 6.20.3 Инициатива и уведомления: условия самостоятельного продолжения
- 6.20.4 Общий контекст: память команды и каналов
- 6.20.5 Идентичность и доступ: чьи полномочия использует агент
- 6.20.6 Командное поручение агенту: назначение исполнителя, общий контекст и проверка результата
- 6.20.7 Промежуточный результат и уведомление: частота, полезность и реакция на изменение задачи

Проектирование и диагностика

- 6.20.8 Несколько руководителей: приоритеты и противоречивые указания
- 6.20.9 Смена участника и продолжение работы: права, ответственность и журнал принятия результата

Фронтир и сравнительные эксперименты

- 6.20.10 Совместное обучение команды работе с агентом: изменение процесса и измерение эффекта

6.21. Поиск и проверка библиографии

- 6.21.1 Исследовательский вопрос: границы корпуса
- 6.21.2 Поисковые выражения: термины, языки и синонимы
- 6.21.3 Цитатные цепочки: основания и развитие идеи
- 6.21.4 Отбор и исключение: прозрачные критерии
- 6.21.5 Метаданные и версии: проверка существования работы
- 6.21.6 Полный текст и доступ: ограничения чтения
- 6.21.7 Дедупликация и каталог: сохранение идентичности записи
- 6.21.8 Карта конференций 2021–2026: треки, годы публикации, версии, награды, отрицательные результаты и репликации

6.22. Чтение и синтез доказательств

- 6.22.1 Утверждение и источник: точная привязка
- 6.22.2 Методы и условия: сопоставимость исследований
- 6.22.3 Таблица свидетельств: поддержка и опровержение
- 6.22.4 Разногласия: причины несовпадения выводов
- 6.22.5 Пробелы: отсутствие данных и ограничения поиска
- 6.22.6 Обзор и систематический обзор: разные обязательства
- 6.22.7 Рецензия как проверяемая обратная связь
- 6.22.8 Научное письмо: тезис, аргумент, абзац, терминология и ясное объяснение сложного механизма
- 6.22.9 Научная коммуникация и популяризация: точность, запоминаемость и границы упрощения

6.23. Гипотезы на основе данных

- 6.23.1 Качество и описание данных: измерения и пропуски
- 6.23.2 Разведочный анализ: поиск закономерностей
- 6.23.3 Формулировка гипотезы: переменные и предсказание
- 6.23.4 Альтернативные объяснения: конкурирующие механизмы
- 6.23.5 Новизна и полезность: проверка по литературе
- 6.23.6 Отложенные данные: независимая проверка
- 6.23.7 Причинные допущения: границы объяснения

6.24. Критика и противодействие поддакиванию

- 6.24.1 Поддакивание: влияние позиции и авторитета пользователя
- 6.24.2 Контрсвидетельства: поиск данных против гипотезы
- 6.24.3 Конкурирующие объяснения: что ещё совместимо с наблюдениями
- 6.24.4 Самокоррекция и внешняя проверка: разные источники сигнала
- 6.24.5 Качество критики: реальные и выдуманные возражения
- 6.24.6 Парные задания: устойчивость к формулировке исследователя
- 6.24.7 Решение после критики: следующий проверяемый шаг

6.25. Эксперименты и управление исследованием

- 6.25.1 Дизайн: данные, исходные сравнения и критерии
- 6.25.2 Абляции и чувствительность: проверка механизма
- 6.25.3 Код и среда: воспроизводимый запуск
- 6.25.4 Статистика: неопределённость и множественные проверки
- 6.25.5 Неудачные результаты: документирование и пересмотр
- 6.25.6 Отчёт: проверяемое происхождение выводов
- 6.25.7 Длительное исследование: смена гипотез и приоритетов
- 6.25.8 Мощность эксперимента, размер выборки и последовательные проверки
- 6.25.9 Предрегистрация, разделение разведочного и подтверждающего анализа
- 6.25.10 Воспроизводимый практикум: аудит репозитория, зависимости, доступ к моделям, затраты и контрольный запуск

6.26. Архитектура Deep Research

- 6.26.1 План поиска: разветвление исследовательского вопроса
- 6.26.2 Чтение и извлечение: сохранение доказательств
- 6.26.3 Контроль покрытия: пробелы и новые направления
- 6.26.4 Синтез и цитаты: проверка каждого существенного вывода
- 6.26.5 Остановка поиска: достаточность и неопределённость
- 6.26.6 Переход к эксперименту: дополнительные компоненты системы
- 6.26.7 Очередь исследовательских вопросов и адаптивное перепланирование
- 6.26.8 Хранилище свидетельств: источник, версия, фрагмент, утверждение и проверка
- 6.26.9 Восстановление исследования после сбоя и смены контекста
- 6.26.10 Обучение поисковой политики и оценка её переноса
- 6.26.11 Оценка Deep Research: полнота поиска, доказательность, остановка и сравнение систем при равном бюджете

6.27. Архитектура научного соисследователя

- 6.27.1 Полный цикл: вопрос, литература, данные, гипотеза, эксперимент и пересмотр
- 6.27.2 Реестр гипотез: основания, конкуренты, предсказания и критерии опровержения
- 6.27.3 Роли генератора, критика, ранжировщика и менеджера экспериментов
- 6.27.4 Критика на каждом этапе: защита от поддакивания и подтверждающего поиска
- 6.27.5 Турниры гипотез и ограничения внутреннего ранжирования
- 6.27.6 Выбор следующего опыта: активное обучение, байесовская оптимизация и ценность информации
- 6.27.7 Среда экспериментов, артефакты, версии данных и журнал запусков
- 6.27.8 Повторения, отрицательные результаты и независимая репликация
- 6.27.9 Долгое исследование: изменение приоритетов и сохранение аргументации
- 6.27.10 Сравнительная архитектура Co-Scientist, AI Scientist и других открытых систем
- 6.27.11 Границы автономии и ответственность исследователя
- 6.27.12 Оценка научного процесса: новизна, проверяемость, человеческая экспертиза и независимое подтверждение

6.28. Документы длинного проекта

- 6.28.1 Паспорт и PRD: проблема, пользователи и требования
- 6.28.2 Спецификация и RFC: обсуждение решения
- 6.28.3 ADR: принятое решение и его основания
- 6.28.4 План и реестр задач: зависимости и готовность
- 6.28.5 Журнал прогресса и handoff: передача между сессиями
- 6.28.6 AGENTS.md, CLAUDE.md и SKILL.md: назначение инструкций
- 6.28.7 Реестр экспериментов и доказательств: научный проект
- 6.28.8 Изменение требований: актуализация документов

6.29. Постановка и проектирование с агентом

- 6.29.1 Исследование репозитория: устройство и зависимости
- 6.29.2 Требования и критерии: проверяемое поведение
- 6.29.3 Архитектура и интерфейсы: границы компонентов
- 6.29.4 ADR и спецификации: сохранение выбора
- 6.29.5 План изменений: последовательность и риски
- 6.29.6 Оценка готовности к реализации: известные неизвестные

6.30. Код, отладка и проверка

- 6.30.1 Декомпозиция изменений: проверяемые шаги
- 6.30.2 Контекст кода: что загрузить для конкретной задачи
- 6.30.3 Тесты и статический анализ: разные виды свидетельств
- 6.30.4 Отладка: воспроизведение и причина ошибки
- 6.30.5 Ревью: проверка человеком и агентом
- 6.30.6 Ветки и рабочие копии: изоляция параллельных изменений
- 6.30.7 Legasy и зависимости: ограничения существующей системы
- 6.30.8 Бенчмарки разработки: SWE-bench, корректность тестов, загрязнение и отличие исправления от сопровождения

6.31. Выпуск и сопровождение

- 6.31.1 CI/CD: проверка и доставка версии
- 6.31.2 Миграции: согласование кода и данных
- 6.31.3 Развёртывание и откат: управление изменениями
- 6.31.4 Мониторинг и инциденты: обнаружение и восстановление
- 6.31.5 Обновления и технический долг: длительное сопровождение
- 6.31.6 Завершение эксплуатации: сохранение данных и решений

6.32. Сквозная оценка LLM-систем

Основы использования

- 6.32.1 Оценка использования: завершена ли задача, есть ли доказательства и пригоден ли артефакт

Повторяемая профессиональная работа

- 6.32.2 Извлечение, ранжирование и генерация: отдельные метрики
- 6.32.3 Цитаты: точность и полнота опоры
- 6.32.4 Задержка, стоимость и полезность: компромиссы
- 6.32.5 Корпоративные задачи: противоречия, недоступные и отсутствующие сведения
- 6.32.6 Личный набор проверочных задач: обычные, сложные, отрицательные и повторные случаи

Проектирование и диагностика

- 6.32.7 Память и действия: проверка траектории
- 6.32.8 Судьи-модели и эксперты: согласование и ограничения
- 6.32.9 Регрессии: обновление моделей и корпуса
- 6.32.10 Доверительные интервалы, мощность и парные сравнения систем
- 6.32.11 Fault injection, нагрузочные испытания и воспроизводимый регрессионный стенд
- 6.32.12 Повторные попытки и горизонт агента: pass@k, стабильность успеха и накопление ошибок
- 6.32.13 Цена успешной задачи: задержки p50/p95, память, сетевой обмен и сопоставимые бюджеты
- 6.32.14 Абляция рабочего процесса: промпт, контекст, навык, инструмент и цикл по отдельности
- 6.32.15 Оценка поведения: неверный инструмент, преждевременная остановка, ложный успех и лишнее действие
- 6.32.16 Проблема оракула: истинность результата, выполнение спецификации и статистическая оценка как разные гарантии

Фронтир и сравнительные эксперименты

- 6.32.17 Оптимизация без подгонки: скрытый тест, независимый оценщик, перенос на новый домен и версия модели
- 6.32.18 Аудит моделей решений: калибровка, селективный риск, экономия в каскаде и независимая проверка правильности

6.33. Права доступа и безопасность

- 6.33.1 Идентификация и авторизация: субъект действия
- 6.33.2 Роли и атрибуты: правила доступа
- 6.33.3 Prompt injection и отравление: недоверенный контент
- 6.33.4 Изоляция и секреты: среда выполнения
- 6.33.5 Отзыв доступа: производные данные и память
- 6.33.6 Аудит и восстановление: проверка внешних действий

6.34. Улучшение, переносимость и стоимость

Основы использования

- 6.34.1 Подписка, API и локальное выполнение: возможности, ограничения и доступные способы практики

Повторяемая профессиональная работа

- 6.34.2 Разбор неудач: классификация причин
- 6.34.3 Маршрутизация: выбор подходящего исполнителя
- 6.34.4 Бюджеты: стоимость полезного результата
- 6.34.5 Перенос рабочего процесса: инструкции, файлы, навыки и контракты без зависимости от истории чата

Проектирование и диагностика

- 6.34.6 Версии промптов, навыков и моделей: воспроизводимость
- 6.34.7 Замена провайдера: зависимости и перенос
- 6.34.8 Повторная оценка: регрессии и критерии сохранения изменений
- 6.34.9 Бюджет пользователя: успешная задача, время человека, вызовы модели, инструменты и сопровождение

Фронтир и сравнительные эксперименты

- 6.34.10 Миграция энкодера: перевод старого индекса, полное переэмбеддирование и тест на новых доменах
- 6.34.11 Перенос адаптеров, весов и поведения: совместимость базовой модели и роль дистилляции
- 6.34.12 Эксперимент A→B: линейный, нелинейный и OT-мосты против переиндексации на отложенных запросах
- 6.34.13 Сравнение готового инструмента и собственного процесса: измеримые преимущества и цена сложности

6.35. Робототехника и воплощённые модели

- 6.35.1 Кинематика и динамика: движение и воздействие
- 6.35.2 Оценивание состояния и восприятие: неполные наблюдения
- 6.35.3 Планирование и управление: цель и обратная связь
- 6.35.4 Обучение по демонстрациям и подкреплению: получение политики
- 6.35.5 Симуляция и sim-to-real: перенос в реальную среду
- 6.35.6 VLA и модели мира: связь языка, зрения и действия
- 6.35.7 Безопасность, задержки и отказы: физические ограничения
- 6.35.8 Локализация и карты: оценка положения и среды

- 6.35.9 Контакт и манипуляция: ограничения взаимодействия с объектами
- 6.35.10 Обратная связь и устойчивость: проверка замкнутого контура
- 6.35.11 Модели мира, embodied AI и diffusion policies

6.36. Экономика ИИ и инфраструктуры

- 6.36.1 Стоимость обучения и инференса: разные структуры затрат
- 6.36.2 Данные и вычисления: рынки, концентрация и открытые модели
- 6.36.3 Задачи и труд: дополнение, замещение и организация работы
- 6.36.4 Производительность: как измерять вклад ИИ
- 6.36.5 Распространение технологии: ограничения внедрения
- 6.36.6 Энергия и центры обработки данных: спрос и сценарии
- 6.36.7 Экономика агентных систем: полная стоимость полезного результата
- 6.36.8 Причинная оценка внедрения: исходная группа, неоднородность эффекта и переносимость
- 6.36.9 Организационные изменения: стимулы, навыки и издержки координации
- 6.36.10 Цена уровня качества и тариф модели: сопоставимые измерения и экономика ансамбля

Блок 7. Вычислительное железо, инфраструктура и локальные модели

7.1. От задачи к конфигурации: вычислительное планирование

- 7.1.1 Задачи: обучение с нуля, SFT/LoRA, пакетные эмбединги, RAG, интерактивная генерация и мультимодальный вывод
- 7.1.2 Масштаб модели: число параметров, плотная или MoE, разрядность, активные параметры и формат весов
- 7.1.3 Нагрузка: входные и выходные токены, длина контекста, пиковая и средняя одновременность
- 7.1.4 Требования к качеству: модель, оценочный набор, ограничения домена и допустимая деградация после сжатия
- 7.1.5 Требования к времени: задержка первого токена, время на токен, p95, пакетная скорость и срок выполнения работы
- 7.1.6 Память как система ограничений: веса, активации, оптимизатор, KV-кэш, индекс и буферы исполнения
- 7.1.7 Потоки данных: где хранится корпус, где выполняется поиск и где запускается модель
- 7.1.8 Режимы владения: собственная машина, сервер, аренда ускорителя и гибридная схема
- 7.1.9 Бюджет решения: стоимость оборудования, электроэнергии, хранения, сопровождения и простоя
- 7.1.10 Паспорт нагрузки: измеримые входы для выбора машины и критерий успешного теста

7.2. Устройство вычислительной системы

- 7.2.1 CPU: ядра, частота, SIMD, число линий PCIe и задачи подготовки данных
- 7.2.2 GPU/ускоритель: вычислительные блоки, поддерживаемая точность, матричные операции и программная совместимость
- 7.2.3 VRAM/HBM: ёмкость против пропускной способности; почему размер модели не равен скорости генерации
- 7.2.4 Оперативная память: объём, каналы, частота, задержки и ECC; влияние на CPU-offload
- 7.2.5 Иерархия памяти: регистры, кэши, память ускорителя, RAM, SSD и сетевое хранилище
- 7.2.6 Шины и связь: PCIe, межускорительные соединения, сеть; скорость передачи против вычислений
- 7.2.7 SSD и NVMe: рабочий набор, последовательный поток, случайный доступ, запись и ресурс носителя
- 7.2.8 Питание, корпус, тепло и акустика: устойчивость частот при долгой нагрузке
- 7.2.9 Производительность в задачах: peak FLOPS, bandwidth, roofline и реальные измерения
- 7.2.10 Версии ПО: драйвер, CUDA/ROCm/Metal, ядра и поддержка нужной точности
- 7.2.11 Физическая и логическая совместимость: габариты карты, питание, слоты, lanes, ОС и библиотеки

7.3. Как обучают большие модели: от узла к кластеру

- 7.3.1 Корпус: сбор, фильтрация, упаковка, потоковая загрузка и балансировка источников
- 7.3.2 Обучающий шаг: forward, loss, backward, обновление; где возникают активации и градиенты
- 7.3.3 Состояние оптимизатора и точность: FP32/FP16/BF16/FP8, master weights и численная устойчивость
- 7.3.4 DP/DDP, tensor, pipeline, expert и context parallelism: что делят между устройствами
- 7.3.5 Шардирование параметров, градиентов и оптимизатора: ZeRO и FSDP
- 7.3.6 Activation checkpointing и gradient accumulation: обмен времени на память
- 7.3.7 Коммуникации: all-reduce, all-gather, reduce-scatter, overlap и топология сети
- 7.3.8 Размещение задач и пропускная способность данных: CPU, память, SSD, object storage, сеть
- 7.3.9 Контрольные точки: частота, объём, восстановление после сбоя и целостность
- 7.3.10 Профилирование: полезная загрузка ускорителей, ожидание данных, связь и узкое место
- 7.3.11 Сравнение кластеров при равном бюджете: токены в секунду, выходное качество и полная стоимость
- 7.3.12 Границы домашнего обучения с нуля: игрушечные модели, доменные модели и фронтирные масштабы

7.4. Как устроен инференс и обслуживание запросов

- 7.4.1 Путь запроса: API, очередь, токенизация, prefill, decode, постобработка и ответ
- 7.4.2 Prefill и decode: разные ограничения по вычислениям и памяти
- 7.4.3 KV-кэш: размер по слоям, KV-головам, длине, числу запросов и типу данных
- 7.4.4 Continuous batching и PagedAttention: управление неодинаковыми длинами запросов
- 7.4.5 Общий префикс, повторное использование KV и изоляция пользовательского контекста
- 7.4.6 Speculative decoding, attention kernels, компиляция и разделение prefill/decode
- 7.4.7 Несколько GPU: разделение весов и памяти; цена обмена через PCIe и сеть
- 7.4.8 Маршрутизация и каскады: SLM, LLM, классификатор решения, ранжировщик
- 7.4.9 Метрики: TTFT, TPOT, токены в секунду, p50/p95, goodput и стоимость успешного запроса
- 7.4.10 Перегрузка: лимиты, admission control, отмена, приоритеты и SLA
- 7.4.11 Безопасность эксплуатации: версионирование, изоляция, логирование и обновление модели
- 7.4.12 Энергопотребление и цена запросов при неполной и полной загрузке сервера

7.5. Хранилища и базы данных в AI-системе

- 7.5.1 Роли хранилищ: исходные файлы, метаданные, задания, индексы, трассы и результаты
- 7.5.2 Реляционная БД: транзакции, SQL, индексы, конкурентные редакторы и версии данных
- 7.5.3 Объектное хранилище и файловая система: большие файлы, версии, контрольные суммы и права
- 7.5.4 Полнотекстовый индекс: инвертированный индекс, BM25, фильтры и обновления
- 7.5.5 Векторный поиск: память эмбеддингов, HNSW/IVF, recall, селективные фильтры и построение индекса

- 7.5.6 Графовая БД: сущности, связи, запросы и отличие от обычных ссылок между таблицами
- 7.5.7 Кэши и очереди: границы консистентности, вытеснение, ретрай и идемпотентность
- 7.5.8 Планировщик запроса и составной поиск: цена join, фильтра, сканирования и rerank
- 7.5.9 CPU, RAM, SSD и GPU для БД: рабочий набор, горячие данные и профилирование ввода-вывода
- 7.5.10 Резервные копии, WAL, миграции схемы, восстановление и разграничение доступа
- 7.5.11 Объёмное планирование: документы → фрагменты → эмбединги → индексы → резервные копии
- 7.5.12 Сценарий 3000+ PDF/Excel и 15 участников: расчёт индексов, тест 20 одновременных запросов и узкие места

7.6. Локальные модели: экосистема и первый запуск

- 7.6.1 Типы моделей: SLM, LLM, embedding, reranker, ASR, TTS, VLM и модели изображений
- 7.6.2 Выбор открытой модели: веса, лицензия, ограничения использования, карточка и проверяемые оценки
- 7.6.3 Форматы: исходный checkpoint, safetensors, GGUF, адаптер LoRA и квантизованные варианты
- 7.6.4 Среды исполнения: Transformers, llama.cpp, vLLM, MLX и оболочки для настольного запуска
- 7.6.5 Выбор CPU, CUDA, ROCm, Metal и других backend по подтверждённой матрице совместимости
- 7.6.6 Загрузка и проверка файлов: версия модели, tokenizer, checksum, шаблон чата и доверие к коду
- 7.6.7 Базовая практика: запуск SLM, запрос, измерение памяти, времени и качества
- 7.6.8 API локального сервера: клиенты, очередь, ограничение доступа и сетевое размещение
- 7.6.9 Запуск при нехватке VRAM: квантизация, offload в RAM, части слоёв и падение скорости
- 7.6.10 Большой контекст на локальном устройстве: KV-кэш, cache quantization и фактическое качество
- 7.6.11 Проверка языков, инструментов, JSON и длинных документов на своих задачах
- 7.6.12 Приватность и сетевые границы: локальные данные, скачивание весов и журналирование

7.7. Расчёт ресурсов: что поместится и что будет работать быстро

- 7.7.1 Масса весов: параметры × бит/8 и поправка на служебные данные формата
- 7.7.2 Объём KV-кэша: слои × KV-головы × размер головы × длина × пакет × 2 × байты
- 7.7.3 GQA, MQA, MLA, sliding window и архитектурные исключения: как меняется оценка кэша
- 7.7.4 Расходы runtime: временные буферы, фрагментация, графы исполнения и рабочее пространство
- 7.7.5 Память в единицах GB и GiB: сравнение паспорта GPU с реальным объёмом весов
- 7.7.6 Число одновременных пользователей: контекст и KV-кэш каждого запроса
- 7.7.7 МоЕ: активные параметры для вычислений и общий объём весов для размещения
- 7.7.8 Одна, две и несколько GPU: суммарная VRAM, деление модели и цена передачи

- 7.7.9 CPU offload: большой объём RAM не гарантирует приемлемую скорость
- 7.7.10 Пропускная способность памяти и токены в секунду: грубая верхняя оценка для decode
- 7.7.11 Обучение: веса, master weights, градиенты, optimizer states и активации отдельно от инференса
- 7.7.12 Квантизация весов и KV-кэша: экономия, поддержка kernel и контроль потерь качества
- 7.7.13 Таблица сценариев по масштабу 1B/3B/8B/14B/32B/70B с измерением на конкретном checkpoint
- 7.7.14 Безопасная оценка: запас памяти, точная конфигурация и пробный запуск до покупки

7.8. Локальное обучение и дообучение

- 7.8.1 Выбор метода: обучение с нуля, продолженное предобучение, полное SFT, LoRA и QLoRA
- 7.8.2 Данные: качество, согласие/лицензия, train/validation/test и формат диалога
- 7.8.3 Бюджет GPU-памяти: базовые веса, адаптер, градиент, оптимизатор, активации и пиковые буферы
- 7.8.4 Параметры обучения: sequence length, microbatch, accumulation, checkpointing и precision
- 7.8.5 LoRA: ранг, модули применения, обучение адаптера и совместимость с базовой моделью
- 7.8.6 QLoRA: замороженные квантизованные веса и обучаемый адаптер; поддержка оборудования
- 7.8.7 Обучение embedding/reranker против дообучения генератора: где возникает польза
- 7.8.8 Малые модели с нуля: воспроизводимый учебный эксперимент и стоимость токенов
- 7.8.9 Проверка качества: независимые задачи, забывание, потери от квантизации и утечки
- 7.8.10 Сохранение и развёртывание: веса, адаптер, версия tokenizer, лицензия и откат
- 7.8.11 Переход от одной GPU к нескольким: FSDP/ZeRO, обмен данными и порог полезности

7.9. Как выбирать компоненты рабочей станции

- 7.9.1 Порядок выбора: задача → модель/режим → память/скорость → платформа → компоненты
- 7.9.2 GPU: VRAM прежде всего для вместимости, затем bandwidth, точность, compute и поддержка ядрами
- 7.9.3 Несколько GPU: равные/разные карты, межсоединение и совместимость конкретного runtime
- 7.9.4 CPU: ядра, однопоток, каналы памяти, PCIe-линии, ввод-вывод и задачи вне GPU
- 7.9.5 RAM: вместимость корпусов, offload, ingestion, индекса и числа процессов; ECC и апгрейд
- 7.9.6 Плата: сокет, BIOS, память, слоты, разъёмы, PCIe lanes/bifurcation и физические зазоры
- 7.9.7 SSD/NVMe: ёмкость моделей, датасетов и checkpoints, TLC/QLC, ресурс записи и резерв
- 7.9.8 Сеть: порт, пропускная способность, удалённый доступ и отдельное хранение корпуса

- 7.9.9 Блок питания: номинал и запас, разъёмы, пики, эффективность и непрерывная нагрузка
- 7.9.10 Корпус и охлаждение: размеры GPU, воздушный поток, температура VRAM/CPU и шум
- 7.9.11 ИБП и электропитание: краткие отключения, корректное завершение и измерение потребления
- 7.9.12 ОС и стек: драйверы, контейнеры, библиотека, версии и подтверждённый тест
- 7.9.13 Мини-ПК, ноутбук и полноразмерный ПК: производительность, память, ремонт и расширение
- 7.9.14 Поддержанное и новое оборудование: тест стабильности, гарантия и ожидаемая стоимость владения
- 7.9.15 Совместимость сборки: чек-лист перед оплатой и план апгрейда на 2–3 года
- 7.9.16 Три спецификации под одну задачу: 16, 24 и 32 GiB VRAM; назначение, ограничения и путь расширения каждой
- 7.9.17 Сначала точный checkpoint и формат, потом GPU: паспорт 20B dense и MoE, KV-кэш, буферы и измеримый запас
- 7.9.18 Видеокарта для инференса и адаптации: VRAM, bandwidth, BF16/FP8/INT4, поддержка kernels и драйвера
- 7.9.19 CPU и RAM для локального узла: парсинг/OCR, индексация, выгрузка модели, двухканальный режим и запас до 128 GiB
- 7.9.20 Материнская плата и память: сокет, BIOS, QVL, число DIMM, PCIe-линии, разделение слотов и M.2
- 7.9.21 Компоновка GPU: длина и толщина конкретной карты, кабели, зазоры, входящий воздух и длительный нагрев
- 7.9.22 Блок питания и электросеть: рекомендация производителя именно для карты, CPU и периферия, разъём и укладка кабеля
- 7.9.23 План SSD и резервирования: ОС, веса, датасеты, checkpoints, индексы, временные записи, TBW и отдельная копия
- 7.9.24 Ведомость закупки: модель каждого компонента, два совместимых варианта, доказательство совместимости и способ возврата
- 7.9.25 Сборка и ввод в эксплуатацию: проверка платы вне корпуса, BIOS, память, монтаж GPU, драйвер, runtime и термотест
- 7.9.26 Контроль после сборки: точный checkpoint, короткий и длинный контекст, QLoRA-шаг, конкуренция, пики VRAM/RAM и p95

7.10. Сервер, кластер и гибридная эксплуатация

- 7.10.1 Домашняя рабочая станция, выделенный сервер, мини-ПК и облачный GPU: режимы применения
- 7.10.2 Несколько пользователей: конкуренция за GPU, очередь, память и независимые данные
- 7.10.3 Сетевая архитектура: локальная сеть, VPN, TLS, авторизация и пределы доверия
- 7.10.4 Отдельные роли: сервер модели, сервер БД, хранилище, воркеры и клиент
- 7.10.5 Контейнеризация, обновления, мониторинг, журналирование и перезапуск сервисов
- 7.10.6 Миграция между платформами: модель, формат, адаптеры, индексы и API-контракт
- 7.10.7 Аренда и собственность: часовая цена против загрузки, обслуживание и пиковый спрос
- 7.10.8 Провайдер и локальное выполнение: приватность, доступность, тариф и переносимость

- 7.10.9 Пределы масштабирования: сетевое взаимодействие, горячие данные и доля последовательной работы
- 7.10.10 План восстановления: backup, тест восстановления, версии и отказоустойчивость

7.11. Практикум: рассчитать, запустить и сравнить

- 7.11.1 Профили доступной VRAM 6/12/24/48+ GiB: что оценивать до выбора конкретной модели
- 7.11.2 Учебный расчёт 8B при 4 битах: около 4 GB сырых весов плюс кэш и накладные расходы
- 7.11.3 Учебный расчёт 32B при 4 битах: около 16 GB сырых весов плюс кэш и накладные расходы
- 7.11.4 Одинаковый запрос на CPU и GPU: пропускная способность, задержка и offload
- 7.11.5 Один пользователь против двадцати: измерение очереди, p95 и расхода KV-кэша
- 7.11.6 RAG-проект 3000+ PDF/Excel: ingest, поиск, reranking, генерация, рост индексов и времени
- 7.11.7 Локальные embedding и reranker на одном узле: фоновые задания против интерактивных
- 7.11.8 LoRA/QLoRA малой модели: peak VRAM, количество шагов, throughput и качество
- 7.11.9 Сравнение мини-ПК и рабочей станции при одном бюджете на общих задачах
- 7.11.10 Заполненный паспорт подбора: совместимость, расчёт памяти, замер скорости и вердикт
- 7.11.11 20B dense: веса BF16/8-bit/4-bit в GB и GiB; условность размера реального квантованного checkpoint
- 7.11.12 20B MoE: общий объём и активные параметры на примере gpt-oss-20b; почему это разные требования
- 7.11.13 16 GiB VRAM: одиночный 20B с подходящим форматом, малый контекст и измерение остатка под KV
- 7.11.14 24 GiB VRAM: запас под адаптерное дообучение 20B при конкретном batch и контексте; пилот обязателен
- 7.11.15 32 GiB VRAM: более длинный контекст или больше одновременных запросов при измеренном KV; без обещания SLA
- 7.11.16 20B с полным обновлением весов: состав памяти mixed precision и AdamW, offload/sharding и цена вычислений
- 7.11.17 QLoRA 20B: квантованная замороженная база, обучаемые адаптеры, активации и тест одного полного шага
- 7.11.18 20B-сервис: один пользователь и двадцать активных генераций при одинаковой модели, контексте и p95
- 7.11.19 Три проверяемые ведомости сборки: GPU/CPU/RAM/плата/SSD/БП/охлаждение/ОС с принятыми компромиссами
- 7.11.20 Протокол приёма и расчёт полной стоимости: совместимость, качество, память, тепловой режим, энергия и цена владения

7.12. Измерение, неисправности и решение о покупке

- 7.12.1 Проверка совместимости до покупки: производитель, драйвер, runtime, модель и тест сообщества
- 7.12.2 Бенчмарк инференса: размер входа и выхода, batch, concurrency, p50/p95 и максимальная память
- 7.12.3 Бенчмарк обучения: токены/с, loss, микропакет, пиковые активации и checkpoints
- 7.12.4 ООМ: причины и последовательность диагностики весов, KV, активаций и фрагментации

- 7.12.5 CPU bottleneck, PCIe offload, дисковый ввод-вывод и перегрев: разные симптомы
- 7.12.6 Оценка поиска: latency, recall, память индекса и время переиндексации
- 7.12.7 Регрессии качества после смены precision, модели, runtime и размера контекста
- 7.12.8 Энергия и совокупная стоимость: измерение ватт-часов на полезную задачу
- 7.12.9 Испытание нескольких пользователей: конкуренция, безопасность данных и справедливые квоты
- 7.12.10 Решение о покупке: сценарии, ограничения, цена, запас, путь апгрейда и критерий возврата