

Локальный ИИ-ПК: сборка и 20B

Одна и та же цифра на коробке GPU ведёт к разным выводам для локального запуска, QLoRA, полного обновления весов и обслуживания нескольких пользователей.

Сколько занимает модель

Начнём с *условной плотной* модели с 20 миллиардами параметров. Нижняя оценка сырых весов $W = Pb/8$: BF16 занимает 40 GB, или 37,25 GiB; восемь бит — 20 GB, или 18,63 GiB; четыре бита — 10 GB, или 9,31 GiB. Файл квантования может содержать scales, метаданные и слои другой точности. К весам добавляются буферы runtime и KV-кэш. Поэтому 16 GiB позволяют попробовать отдельную 4-bit 20B с ограниченным контекстом, но не произвольный checkpoint; на 24/32 GiB остаётся больше места для кэша и экспериментов.

Карточка gpt-oss² даёт конкретный иной случай: МоЕ с 20,9B общих параметров, 3,6B активных на токен и 12,8 GiB файлом MXFP4. Разработчик сообщает о запуске на системе с 16 GB памяти. Из этого нельзя вывести пригодную скорость или вместимость длинного контекста на всякой GPU. Вычисляемая часть экспертов и полный объём весов — разные величины. У плотной 20B этого различия нет.

При выборе карты проведите три записи. Первая — размер скачанного файла и схема квантования. Вторая — занятая VRAM после загрузки без запросов: в неё могут войти распакованные слои и буферы. Третья — пик после ответа с целевой длиной ввода и вывода. Если он близок к пределу, успешный короткий запрос не даёт запаса для следующего клиента. На карте, обслуживающей дисплей, проверьте фактически свободную VRAM до запуска модели.

Кэш и число запросов

Для полного обычного KV-кэша учебная формула $K = 2LH_{KV}DSBs$, где S — длина удерживаемого контекста, B — число одновременно активных последовательностей. У условной модели с 32 слоями, восьмью KV-головами шириной 128, $S = 4096$ и BF16 получается 0,5 GiB на один запрос и 10 GiB на двадцать. Это *не* параметры gpt-oss: его архитектура и режим внимания другие. Практический пик измеряют в выбранном runtime, учитывая allocator, контекст и работающие рядом embedding/OCR.

Удвоение S в этом примере примерно удваивает KV; четыре активные генерации расходуют около 2 GiB. Это ещё не полная память и не прогноз задержки. Запишите обычную и верхнюю длину запросов, а не только максимум из карточки модели. В документной системе длинные извлечённые фрагменты могут превратить удачный короткий тест в нехватку памяти.

20B dense: только веса

BF16

40 GB = 37,25 GiB.

8 бит

20 GB = 18,63 GiB.

4 бита

10 GB = 9,31 GiB.

Сверх веса

KV, временные буферы и память других процессов. 20 пользователей не всегда означают 20 активных генераций.

МоЕ

Активные параметры задают часть работы; полный checkpoint надо где-то разместить.

Далее

Три сборки и приёмка машины.

Адаптерное и полное обучение

В QLoRA³ базовые веса заморожены и квантизованы; обновляются адаптеры LoRA. PEFT⁴ показывает путь 4-bit загрузки и подготовки к обучению. Для 20B видеокарта с 24–32 GiB — кандидат на пилот при умеренных длине и microbatch, а 16 GiB может потребовать жёстких ограничений или не вместить шаг. Ранг адаптера, активации, временные буферы и особенности ядра определяют реальный пик. Проверка включает forward, backward, шаг оптимизатора, запись и повторную загрузку адаптера. Замер одной только загрузки модели не считается успехом.

Начните с короткого батча и зафиксируйте ранг LoRA, целевые слои, длину последовательности, точность и gradient checkpointing. Затем повышайте длину до реальных документов. Gradient accumulation увеличивает эффективный размер батча, но не устраняет память одного слишком длинного примера. После шага подключите сохранённый адаптер к той же версии базы и проверьте качество на отложенном наборе: есть ли выигрыш относительно работы без дообучения? Полная настройка всех весов меняет масштаб. В разборе Hugging Face¹ для типичного mixed precision с AdamW: две копии весов требуют 6 байт на параметр, состояния оптимизатора 8, градиенты 4. Итого $20 \cdot 10^9 \cdot 18 = 360$ GB, около 335,3 GiB до активаций и временных буферов. Другие оптимизаторы, offload и шардирование меняют распределение памяти ценой вычислений и обмена. Одна потребительская GPU с 16–32 GiB не является обычной конфигурацией для такого полного шага. Обучение 20B с нуля требует вдобавок огромного корпуса и многих шагов; маленькую модель с нуля на домашней машине обучать можно.

Выгрузка на CPU требует RAM и времени передачи. Несколько GPU требуют проверки того, что стек делит нужные состояния, а не копирует модель на каждой карте. Простое сложение VRAM двух карт не доказывает вместимость. Паспорт полного обучения задаёт алгоритм разделения, число токенов, время работы и план восстановления checkpoint до закупки.

Продакшен проверяется отдельно

Одиночный локальный сервер и двадцать одновременно генерирующих запросов — разные задачи. На рабочей станции возможен небольшой внутренний сервис при очереди, мониторинге и понятном времени простоя. Нужны измерения p95, KV, качества, питания и восстановления; объём VRAM сам по себе не задаёт SLA. Если при целевой нагрузке узел не проходит, надо уменьшить модель или контекст, ввести очередь, либо сменить класс машины.

Пилот QLoRA

1. Загрузка

Точный checkpoint.

2. Шаг

Backward и оптимизатор.

3. Проверка

Пик VRAM и файл адаптера.

4. Масштаб

Целевой контекст.

Полный шаг

18 байт × 20B = 360 GB в указанной схеме AdamW без активаций.

БИБЛИОГРАФИЯ

ВВОДНЫЕ РАБОТЫ

1. Hugging Face (документация, 2026), *GPU memory usage*. Документация.

Расход памяти GPU при обучении

Типичный mixed precision с AdamW разбит на две копии весов, градиенты, состояния оптимизатора, активации и временные буферы. Указанные 18 байт на параметр относятся к конкретному способу полного обучения.

Что читать. Tensors, activations и temporary tensors: сложить $6 + 8 + 4$ байт и указать исключённые расходы.

2. OpenAI (2025), *gpt-oss model card*. Технический отчёт.

Техническая карточка моделей gpt-oss

Для gpt-oss-20b приведены 20,9B общих, 3,6B активных параметров и 12,8 GiB файла checkpoint в MXFP4. Указана возможность запуска в системе с 16 GB памяти. Это частный MoE пример, а не обещание для любой плотной 20B.

Что читать. Раздел 2, таблица 1: различить общие, активные параметры и полный размер файла.

3. Dettmers, T. и др. (2023), *QLoRA: Efficient Finetuning of Quantized LLMs*. NeurIPS.

QLoRA: адаптация поверх квантизированной замороженной базы

База заморожена и квантизована, а градиенты обновляют низкоранговые адаптеры. Для отдельного checkpoint всё ещё нужны измерения пиков активаций, временных буферов и поддержки слоёв.

Что читать. §3 о NF4, double quantization и paged optimizers; восстановить память одного шага.

4. Hugging Face (документация, 2026), *Quantization with PEFT*. Документация.

Квантизация базы и обучение адаптеров PEFT

Показывает практический путь 4-bit загрузки модели и обучения LoRA. Пример доказывает существование метода, но не вместимость произвольной 20B на 16 GiB VRAM.

Что читать. Пример загрузки 4-bit и `prepare_model_for_kbit_training`: выполнить forward, backward, шаг оптимизатора.

Порядок чтения. Начать с разложения памяти Hugging Face. В карточке gpt-oss отделить полный checkpoint от активных экспертов. QLoRA объясняет экономию, а PEFT даёт контрольный шаг для своей модели.

Три сборки и приёмка машины

16, 24 и 32 GiB — не готовые сертификаты совместимости, а отправные классы закупки. Каждая ведомость фиксирует точные детали и проходит одинаковые тесты.

Порядок составления ведомости

Сначала запишите checkpoint, формат, runtime, ОС, длины входа и выхода, число одновременных генераций, цели TTFT и p95. Для QLoRA — длину примера, microbatch и ранг. Затем оцените веса и KV либо активации и оставьте запас для runtime. Только после этого выбирайте GPU по VRAM, поддержке формата и ядер, bandwidth, питанию и габаритам. Поддержка семейства моделей не заменяет пробный запуск точной ревизии.

Для учебной системы с PDF/OCR, локальной БД и одной 20B возьмите как исходную, *не обязательную*, базу: современный CPU примерно 8–16 ядер, 64 GiB RAM двумя модулями с путём к 128 GiB, NVMe порядка 2 TB для ОС/моделей и отдельное рабочее место порядка 2 TB для данных, индексов и checkpoints. Если параллельно идёт много OCR или нужен offload, считайте RAM по пику процессов; если часто пишутся checkpoints, сверяйте ресурс SSD и свободное место. Копия на другом носителе нужна для восстановления, а не для увеличения рабочего объёма.

Такой CPU выбирают под подготовку данных, токенизацию, базу и очередь, а не по обещанию ускорить GPU-bound decode числом ядер. Память ищите по точному комплекту в списке совместимости платы: четыре модуля могут потребовать иных настроек, чем два. Для платы проверьте поддержку процессора текущим BIOS, режим основного PCIe x16 при занятых M.2 и свободное место для толстой GPU. Вторую GPU планируют только после проверки линий, зазоров, БП и способности runtime разделить модель.

16 и 24 GiB

В классе 16 GiB пример — RTX 5080¹. Назначение: одиночный квантованный 20B с проверенным контекстом или более компактная модель плюс RAG. BF16 веса плотной 20B уже превышают VRAM. QLoRA 20B здесь только пилот без обещания. У референсной карты TGP 360 W, а системная рекомендация NVIDIA составляет 850 W при оговорённой конфигурации.

В классе 24 GiB пример — RTX 4090². Больше запаса для 4-bit 20B и адаптерного обучения, если полный шаг помещается. Но BF16 плотной 20B всё ещё не входит целиком. Референсная карта имеет TGP 450 W и рекомендацию системы 850 W при указанном составе. Для подержанной карты проверяют состояние, длительный термотест и условия возврата.

У каждой сборки одинаковая проверка диска. Сложите файлы модели с резервной версией, документы, индекс, обучающий набор, временные данные и несколько checkpoint. Сравните с доступным местом после установки ОС; предусмотрите место для переиндексации. Последовательная скорость SSD из рекламы не описывает каждую мелкую операцию базы: если она важна, измерьте её на своих документах.

Ведомость

GPU и VRAM; CPU и сокет; плата/BIOS/QVL; RAM и слоты; SSD и резерв; БП/кабель; корпус/охлаждение; ОС/runtime.

A: 16 GiB

Одиночный 4-bit; измерить остаток под KV.

B: 24 GiB

4-bit и QLoRA-пилот; полный учебный шаг обязателен.

32 GiB и общий предел

В классе 32 GiB пример — RTX 5090³. Запас расширяет выбор контекста, числа запросов и параметров пилота QLoRA. BF16 плотной 20B не помещается на этой карте целиком, а обычное полное обучение остаётся за пределами одной GPU. У референса TGP 575 W и рекомендованная системная мощность от 1000 W при оговорённой конфигурации. Для карты партнёра сверяются фактические размеры, толщины, кабели и воздушный поток: паспорт Founders Edition не описывает всякий вариант.

Запас VRAM расходуется по-разному: более длинный контекст, больше одновременных запросов или соседние embedding и reranker конкурируют за одну память. Проверяйте устойчивую скорость после прогрева, а не только первые секунды: температура и ограничение мощности могут изменить результат.

Совместимость до оплаты

В ведомости укажите *точный артикул* каждой детали и ссылку производителя. Плата: сокет и BIOS для CPU, QVL комплекта RAM, PCIe-линии при занятых M.2 и доступные места для GPU. Корпус: длина и толщина карты с зазором для кабеля, охлаждение при длительной нагрузке. БП: мощность для всей системы, штатный разъём и подключение по инструкции изготовителя карты. SSD: модели, версии, дата-сеты, индексы, checkpoint, временные файлы и ресурс записи. Вариант апгрейда проверьте на той же плате. Если точного SKU ещё нет, запись «совместимо» оставьте открытой.

После сборки: POST, BIOS, RAM, SSD, обнаружение GPU, драйвер и runtime. Затем запуск точного checkpoint при коротком и целевом контексте; запишите пик VRAM/RAM и температуру после прогрева. Для обучения проведите один полный шаг и сохраните адаптер. Для сервиса испытайте один, четыре и двадцать активных запросов с тем же распределением длины; Benchmark CLI vLLM⁴ помогает фиксировать TTFT, TPOT и throughput. Отдельно измерьте p95 и качество ответов на собственном наборе. Решение «годится» относится только к названному checkpoint, нагрузке и проверенной версии ПО.

В итоговом паспорте укажите цену покупки, стоимость работы, ожидаемый простой и цену замены детали. Проверьте резервную копию пробным восстановлением. Формулируйте вывод условно: «эта сборка при четырёх генерациях и заданном контексте выдержала установленный p95». Новая модель, формат или драйвер требуют новой проверки.

C: 32 GiB

Больше KV и пространства для QLoRA; не полное обучение 20B.

Приёмка

Вместимость

Вес, KV или активации, реальный пик.

Скорость

TTFT, TPOT, p95 при 1/4/20.

Качество

Свой набор заданий.

Надёжность

Термотест, резерв, восстановление.

БИБЛИОГРАФИЯ

ВВОДНЫЕ РАБОТЫ

1. NVIDIA (спецификация, 2026), *GeForce RTX 5080 specifications*. Спецификация.

Характеристики GeForce RTX 5080

Референс имеет 16 GB GDDR7, TGP 360 W и рекомендацию системного БП 850 W для оговорённой конфигурации. Разъём и размеры партнёрской карты сверяются отдельно.

Что читать. Memory Specs, Card Dimensions, Thermal and Power Specs; повторить сверку у производителя платы.

СПЕЦИАЛИЗИРОВАННЫЕ РАБОТЫ

2. NVIDIA (спецификация, 2026), *GeForce RTX 4090 specifications*. Спецификация.

Характеристики GeForce RTX 4090

Референсная карта имеет 24 GB памяти, TGP 450 W и рекомендацию системы от 850 W для приведённой производителем конфигурации. У б/у карты состояние и условия возврата проверяются отдельно.

Что читать. Memory Specs и Power Specs; сопоставить артикул с карточкой продавца.

3. NVIDIA (спецификация, 2026), *GeForce RTX 5090 specifications*. Спецификация.

Характеристики GeForce RTX 5090

Референсная карта имеет 32 GB GDDR7, TGP 575 W и рекомендацию системы от 1000 W при оговорённом составе ПК. Большая память не обещает низкую задержку при многопользовательской работе.

Что читать. Memory Specs и Power Specs; отдельно проверить габариты и кабель конкретной карты.

4. vLLM (документация, 2026), *Benchmark CLI*. Документация.

Инструмент измерения сервера vLLM

Описывает генератор нагрузки и задержки TTFT, TPOT, throughput. На нём можно сравнить одно и двадцать активных обращений, если checkpoint, длины запросов и настройки сервера сохранены.

Что читать. Benchmark serving: составить два сопоставимых опыта и записать p95 и пик VRAM.

Порядок чтения. Сравнить спецификации трёх референсных карт и проверить конкретную карту партнёра. Затем по документации Benchmark CLI воспроизвести испытание на точной модели при фиксированных длинах и числе активных генераций.