

Конференции и движение исследований искусственного интеллекта

Рамки и принцип отбора

Обзор охватывает конференционные годы 2021–2026 по состоянию на 12 сентября 2026 года. Его задача — выявить линии развития, необходимые для Атласа LLM, RAG, агентов и Deep Research. Это тематический исследовательский обзор 50 опорных работ, а не полный переписной каталог всех принятых статей и не библиометрический рейтинг. Выборка позволяет обосновать изменения учебной структуры, но не измеряет доли направлений во всей области.

Год конференции отделён от года препринта: LoRA относится здесь к ICLR 2022, хотя первая версия появилась в 2021; Mamba — к COLM 2024, хотя препринт вышел в 2023. Статус position paper, короткой статьи и Datasets and Benchmarks отмечен отдельно. Награда служит сигналом для чтения, а не доказательством истинности. Официальные критерии ICML прямо различают позиционную аргументацию и сообщение нового исследовательского результата (правила трека).

Для основного реестра проверены первичные карточки, аннотации и доступные библиографические сведения. Для AlphaEdit, DistServe, Conformal Language Modeling, критики RLVR, Flexibility Trap и работ о межмодельном обмене дополнительно просмотрены релевантные части полного HTML. Полный аудит доказательств и независимое воспроизведение экспериментов не проводились. Все русские названия являются рабочими смысловыми переводами.

2026 год неполон: учитываются уже доступные публикации и объявленные результаты, включая ICML и ICLR. Отсутствие работы в подборке не означает отсутствия направления на конференции. Для недавних результатов пока невозможно установить долговременное влияние.

Карта конференций

Приоритет означает полезность для данного Атласа, а не универсальный рейтинг научного престижа. Внутри каждой группы следует читать основные статьи, наборы данных, репликации и критические работы. Воркшопы служат источником ранних направлений и учитываются отдельно от основного трека.

Группа	Конференции	Что искать для Атласа
Основное ML	ICML, NeurIPS, ICLR	Обучение, представления, генерация, RL, теория и оценка
Язык	ACL, EMNLP, NAACL, EACL, COLING, COLM	LLM, многоязычие, аргументация, извлечение, агенты
Поиск и данные	SIGIR, WSDM, The Web Conference, KDD, CIKM	Ranking, sparse/dense retrieval, рекомендательные системы, графы
Зрение	CVPR, ICCV, ECCV	Мультимодальность, зрительные представления, видео, генерация
Вычислительные системы	MLSys, ASPLOS, SOSP, OSDI, EuroSys	Память, компиляторы, параллелизм, serving, нагрузка
Базы данных	SIGMOD, VLDB, ICDE	Индексы, транзакции, потоки и управление данными для RAG

Группа	Конференции	Что искать для Атласа
Теория и неопределённость	COLT, AISTATS, UAI, CLeaR, ALT	Обобщение, причинность, статистические гарантии, выразительность
Агенты и планирование	AAMAS, ICAPS, AAAI, IJCAI	Координация, поиск планов, обучение взаимодействию
Робототехника	CoRL, RSS, ICRA, IROS	Политики, модели мира, воплощённые агенты, sim-to-real
Инженерия ПО	ICSE, FSE, ASE, ISSTA	Исправление кода, тестирование, оценка агентов разработки
Люди и организации	CHI, CSCW, UIST, FAccT, AIES	Интерфейсы, коллективная работа, доверие, влияние и ответственность
Безопасность	USENIX Security, IEEE S&P, ACM CCS, NDSS	Извлечение данных, отравление, угрозы и проверка защиты
Речь и звук	Interspeech, ICASSP	Речевые модели, аудио, потоковая обработка и задержки
Музыка и документы	ISMIR, ICDAR	Музыкальные представления, OCR, распознавание структуры документов

Основные открытые точки входа: PMLR, NeurIPS Proceedings, ICLR Proceedings, ACL Anthology, COLM, MLSys Proceedings, SIGIR и USENIX. Для ACM/IEEE и CVF доступность полного текста проверяется у каждой работы; нельзя подменять прочитанную статью одной ссылкой на библиотеку.

Самая плотная выборка ниже относится к ICML, NeurIPS, ICLR и смежным LLM-площадкам. Теория, базы данных, инженерия ПО, аудио и специальные прикладные конференции представлены картой поиска, но не равномерным обзором каждого года. Для обнаружения пропусков Атласа это существенное ограничение: эти ветки требуют собственной тематической выборки, а не вывода «важного больше нет».

Как менялась исследовательская постановка

2021: переносимые представления и проверка обобщения

ViT, CLIP и Perceiver показывают разные способы унификации представлений и вычисления [P01, P02, P06]. BEIR одновременно напоминает: успех на привычном наборе не доказывает переноса в другой домен [P04]. Для Атласа это две стороны одной темы: как получить универсальное представление и как проверить пределы его универсальности. SPLADE сохраняет продуктивную связь нейронного обучения с лексическим поиском [P05], а извлечение обучающих данных делает запоминание наблюдаемой проблемой безопасности [P07].

2022: бюджет, предпочтения и инженерия становятся частью модели

Chinchilla рассматривает баланс размера и данных; InstructGPT — изменение цели с предсказания текста на поведение, предпочтительное человеку [P09, P10]. LoRA и

FlashAttention показывают, что доступность обучения зависит от структуры обновления и движения данных [P08, P12]. RETRO помещает извлечение внутрь модели, а ROME — исправление факта внутрь весов [P14, P16]. Поэтому раздел «где находятся знания» должен включать параметры, контекст и внешнюю базу как различные механизмы.

2023: от одного вызова к составному вычислению

ReAct и Toolformer связывают модель с инструментами; DPO меняет процедуру обучения предпочтениям [P17, P18, P26]. PagedAttention и speculative decoding меняют организацию исполнения [P20, P21]. Генеративные модели расходятся на несколько вычислительных подходов: flow matching, consistency, latent diffusion и политики действий [P13, P22, P23, P27]. Общий вывод — архитектура теперь должна описывать и процесс, и среду его исполнения.

2024: система становится единицей исследования

Self-RAG, DSPy и STORM обучают или организуют многоэтапные процессы [P29, P31, P32]. SWE-bench оценивает изменение реального репозитория, а DistServe — обслуживание потока запросов в пределах требований задержки [P30, P36]. Mamba расширяет выбор механизма состояния, SGLang связывает граф программы с переиспользованием вычислений [P34, P38]. Это основание изучать интерфейсы, состояние и оценку сквозного результата наравне с архитектурой сети.

2025: качество требует разложения на несколько осей

AlphaEdit требует учитывать последствия последовательных правок [P39]. Критика RLVR различает успех одной попытки и покрытие решений, а Artificial Hivemind — качество и разнообразие открытых ответов [P41, P42]. Работа о test-time compute связывает полезность дополнительных ресурсов со сложностью вопроса [P43]. Награды ICLR и NeurIPS подтверждают внимание сообщества к этим вопросам, но не заменяют проверку отдельных результатов (ICLR 2025; NeurIPS 2025).

2026: пересмотр универсальных объяснений и новые интерфейсы

Aristotelian View пересматривает измерение общей геометрии, Flexibility Trap — пользу свободы порядка генерации, а Cache-to-Cache — формат обмена моделями [P47, P48, P46]. Теоретическая работа о компактности Transformer показывает, что выразительность и проверяемость могут вступать в напряжение [P49]. Эти примеры не доказывают единого «поворота всей области», но дают конкретные вопросы для пересмотра учебного содержания. Статусы наград проверены по ICML 2026 и ICLR 2026.

Изменения содержания Атласа

В существующей карте уже присутствуют LoRA, Chinchilla, MoE, SSM, flow matching, PRM, адаптивный поиск, инфраструктура и многоагентность. Их не следует повторно объявлять новыми главами. Редактирование знаний уже присутствует в 5.1.5, калибровка — в 5.2.3, а системы инференса — в 3.7. Предлагается раскрыть различия между задачами и критериями проверки внутри этих разделов.

Предложение	Статус относительно карты	Содержание дополнения
Геометрия и сравнение представлений	Углубление 2.4	Нулевая калибровка, соседства против расстояний, идентифицируемость выравнивания [P33, P47]

Предложение	Статус относительно карты	Содержание дополнения
Редактирование знаний	Углубление 5.1.5	ROME → AlphaEdit; локальность, последовательные правки, многошаговые следствия [P16, P39]
Статистическая надёжность ответа	Углубление 1.2 и 5.2.3	Калибровка, множество ответов, abstention, условия гарантий [P37, P45]
Диффузионные языковые модели	Сделать явной подтемой 2.10	Порядок генерации, параллелизм, RL и разнообразие решений [P48]
Формальная выразительность	Углубление 1.7 и 2.5	Автоматы, языки, компактность, вычислительная сложность проверки [P49]
Эффект RLVR	Углубление 4.2	pass@1 против pass@k, exploration, покрытие и дистилляция [P35, P41, P43]
Разнообразие и независимость	Углубление 6.19 и 6.32	Различия ответов, корреляция ошибок, качество критики и гипотез [P42]
Serving и goodput	Углубление 3.7 и 6.18	TTFT, TPOT, очереди, разделение фаз, KV-передачи [P20, P36, P38]
Внутренние интерфейсы моделей	Углубление 6.19	Текст против KV-cache, обучаемые мосты, стоимость и совместимость [P46]
Retrieval-augmented pretraining	Развести с прикладным RAG	RETRO, обучение извлечению, зависимость от корпуса [P14, P29]
Мультимодальная архитектура	Углубление 2.11	CLIP → инструкции → интерфейс действия; восприятие отдельно от речи [P02, P24, P25, P27]
Запоминание и утечки	Связать блоки 1, 3 и 5	Ёмкость, verbatim extraction, membership inference и обобщение [P07, P50]

Приоритет для следующей редакции: редактирование знаний; статистическая надёжность; диффузия текста; формальная выразительность; разнообразие и покрытие решений. Это предложения к содержанию, а не утверждённое изменение нумерации.

Как читать подборку

Для архитектурного маршрута: P09 → P12 → P20 → P36 → P38 → P46. Для RAG и Deep Research: P04 → P05 → P15 → P14 → P29 → P32. Для рассуждения: P11 → P17 → P35 → P43 → P41 → P48. Для представлений и знаний: P02 → P33 → P47 → P16 → P39. Для проверки качества: P07 → P30 → P37 → P42 → P49.

После каждой цепочки полезен один сравнительный эксперимент. Для RAG — одинаковый корпус и бюджет при BM25, sparse, dense и late interaction. Для агентов — один исполнитель,

независимые попытки и взаимодействующая команда при одинаковом бюджете. Для редактирования — целевой факт, перефразировки, связанные следствия и регрессии. Для serving — нагрузочный профиль, доля запросов в SLO и стоимость успешного результата.

Аннотированная библиография

У каждой записи приведены авторы, оригинальное название, перевод, конференционный год, ссылка и адрес в Атласе. Обозначения P01–P50 — устойчивые идентификаторы этого обзора. Они не заменяют номера глав Атласа.

Работы 2021 года

P01. Alexey Dosovitskiy et al.. *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*. ICLR, 2021.

Изображение стоит 16×16 слов: Transformer для распознавания изображений.

Изображение разбивается на патчи и обрабатывается Transformer. Для Атласа это переход от архитектуры, специально устроенной под изображение, к общей последовательностной основе. Значение имеют объём предобучения и индуктивные предпосылки; результат не означает ненужность CNN.

Место в Атласе: 2.5; 2.11.

P02. Alec Radford et al.. *Learning Transferable Visual Models From Natural Language Supervision*. ICML, 2021.

Обучение переносимых зрительных моделей по естественно-языковому надзору.

CLIP связывает изображения и текст контрастивной целью. Языковое описание становится способом задать класс без отдельного обучения классификатора. Это основа разговора о мультимодальных пространствах, но сходство эмбеддингов не гарантирует понимания композиции и отношений.

Место в Атласе: 2.4; 2.11.

P03. Jiaming Song, Chenlin Meng, Stefano Ermon. *Denoising Diffusion Implicit Models*. ICLR, 2021.

Неявные диффузионные модели удаления шума.

DDIM меняет процедуру генерации, сохраняя связь с обучением DDPM. Работа помогает разделить обучающую цель, стохастическую модель и численный процесс получения образца. Ускорение следует изучать вместе с компромиссом качества и числа шагов.

Место в Атласе: 2.10.

P04. Nandan Thakur et al.. *BEIR: A Heterogenous Benchmark for Zero-shot Evaluation of Information Retrieval Models*. NeurIPS, Datasets and Benchmarks, 2021.

BEIR: разнородный тест поиска без обучения на целевой задаче.

Сопоставляет поиск на разных доменах вместо одного привычного корпуса. Показывает необходимость сильного BM25-сравнения и учёта стоимости reranking и late interaction. Рейтинг конкретных моделей исторический; перенос на собственный корпус нужно проверять заново.

Место в Атласе: 6.32; 2.4.

P05. Thibault Formal, Benjamin Piwowarski, Stéphane Clinchant. *SPLADE: Sparse Lexical and Expansion Model for First Stage Ranking*. SIGIR, short paper, 2021.

SPLADE: разреженная лексическая модель с расширением для первого этапа ранжирования.

Нейронное расширение терминов сочетается с разреженным представлением и инвертированным индексом. Это важная альтернатива ложному выбору между BM25 и плотными векторами. Проверены описание метода и библиография авторского репозитория; полный текст версии SIGIR здесь не разобран.

Место в Атласе: 2.4; раздел RAG.

P06. Andrew Jaegle et al.. *Perceiver: General Perception with Iterative Attention*. ICML, 2021.

Perceiver: общее восприятие с итеративным вниманием.

Латентный массив отделяет размер входа от основной вычислительной обработки. Cross-attention связывает вход с этим массивом. Работа полезна как архитектурный контрпример: мультимодальность не сводится к простому объединению всех токенов в одно полное внимание.

Место в Атласе: 2.8; 2.11.

P07. Nicholas Carlini et al.. *Extracting Training Data from Large Language Models*. USENIX Security, 2021.

Извлечение обучающих данных из больших языковых моделей.

Демонстрирует извлечение конкретных обучающих последовательностей из GPT-2. Это связывает запоминание с наблюдаемой утечкой, а не только с качеством на тесте. Необходимо различать extraction, membership inference и обобщение; масштабы риска зависят от модели и процедуры атаки.

Место в Атласе: 3.1; блок 5.

Работы 2022 года

P08. Edward J. Hu et al.. *LoRA: Low-Rank Adaptation of Large Language Models*. ICLR, 2022.

LoRA: низкоранговая адаптация больших языковых моделей.

Обновление весов параметризуется произведением низкоранговых матриц при замороженной основе. Это уменьшает число обучаемых параметров и стоимость хранения адаптаций. Следует отдельно оценивать память активаций, пригодность выбранного ранга и переносимость адаптера.

Место в Атласе: 3.4.

P09. Jordan Hoffmann et al.. *Training Compute-Optimal Large Language Models*. NeurIPS, 2022.

Обучение больших языковых моделей при оптимальном распределении вычислений.

Chinchilla переносит внимание с одного числа параметров на баланс модели и токенов при заданном бюджете. Для проектирования важен совместный выбор данных и размера сети. Полученные соотношения не являются универсальной константой для всех смесей данных и стоимости эксплуатации.

Место в Атласе: 3.2.

P10. Long Ouyang et al.. *Training language models to follow instructions with human feedback*. NeurIPS, 2022.

Обучение языковых моделей следованию инструкциям с человеческой обратной связью.

InstructGPT связывает демонстрации, предпочтения, модель награды и RL. Качество продолжения текста и полезность ответа пользователю становятся разными целями. Предпочтение разметчика не равнозначно фактической истинности и не устраняет ошибок.

Место в Атласе: 4.1.

P11. Jason Wei et al.. *Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*. NeurIPS, 2022.

Промптинг с цепочкой рассуждений вызывает рассуждение в больших языковых моделях.

Промежуточные шаги в примерах улучшают решение ряда задач. Это важная точка перехода к управлению вычислением через последовательность. Наблюдаемый текст объяснения нельзя автоматически считать верным отчётом о внутренних механизмах.

Место в Атласе: 4.2.

P12. Tri Dao et al.. *FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness*. NeurIPS, 2022.

FlashAttention: быстрое точное внимание с учётом обмена с памятью.

Алгоритм уменьшает обращения к памяти посредством блочного вычисления внимания. Ключевой урок: та же математическая операция может иметь совершенно разную аппаратную стоимость. Точное внимание здесь не следует путать с линейным приближением внимания.

Место в Атласе: 3.3; 3.7.

P13. Robin Rombach et al.. *High-Resolution Image Synthesis with Latent Diffusion Models*. CVPR, 2022.

Синтез изображений высокого разрешения латентными диффузионными моделями.

Диффузия выполняется в сжатом пространстве автоэнкодера. Разделение представления и генерации сокращает стоимость обработки изображения. Качество кодирования ограничивает доступные детали; архитектура декодера и условное управление остаются частью системы.

Место в Атласе: 2.10; 2.11.

P14. Sebastian Borgeaud et al.. *Improving language models by retrieving from trillions of tokens*. ICML, 2022.

Улучшение языковых моделей извлечением из триллионов токенов.

RETRO включает извлечение в устройство и обучение модели. Это отличается от добавления найденных фрагментов к промπτу готовой LLM. В Атласе нужно разделить retrieval-augmented pretraining и прикладной RAG, включая стоимость базы и риск утечки.

Место в Атласе: 3.2; раздел RAG.

P15. Keshav Santhanam et al.. *ColBERTv2: Effective and Efficient Retrieval via Lightweight Late Interaction*. NAACL, 2022.

ColBERTv2: эффективный поиск с облегчённым поздним взаимодействием.

Сохраняет несколько векторов документа и сопоставляет их с запросом на позднем этапе. Это промежуточный выбор между одним вектором и полным cross-encoder. Сжатие представлений важно для размера индекса; качество следует сравнивать при одинаковых ресурсах.

Место в Атласе: 2.4; раздел RAG.

P16. Kevin Meng et al.. *Locating and Editing Factual Associations in GPT*. NeurIPS, 2022.

Локализация и редактирование фактических ассоциаций в GPT.

ROME использует причинные вмешательства и адресное изменение весов для обновления ассоциации. Это отдельная задача, отличная от общего дообучения и RAG. Успешная правка одного ответа ещё не доказывает согласованность всех связанных выводов.

Место в Атласе: блок 5; 3.4.

Работы 2023 года

P17. Shunyu Yao et al.. *ReAct: Synergizing Reasoning and Acting in Language Models*. ICLR, 2023.

ReAct: соединение рассуждения и действия в языковых моделях.

Чередует промежуточный текст и действия во внешней среде. Наблюдение после действия позволяет пересмотреть следующий шаг. Это полезная основа контура агента; надёжность транзакций, восстановление и полномочия требуют дополнительных компонентов.

Место в Атласе: 6.15; 6.17.

P18. Rafael Rafailov et al.. *Direct Preference Optimization: Your Language Model is Secretly a Reward Model*. NeurIPS, 2023.

Прямая оптимизация предпочтений: языковая модель неявно задаёт модель награды.

DPO выражает обучение по предпочтениям через прямую цель без отдельного цикла PPO в исходной постановке. Упрощение процедуры делает важнее понимание её математических предпосылок. Качество пар предпочтений и сдвиг распределения по-прежнему ограничивают результат.

Место в Атласе: 4.1.

P19. Tim Dettmers et al.. *QLoRA: Efficient Finetuning of Quantized LLMs*. NeurIPS, 2023.

QLoRA: эффективное дообучение квантованных языковых моделей.

Совмещает квантованную замороженную основу и обучаемую адаптацию. Практическая ценность — снижение требований к памяти дообучения. Это не означает, что весь процесс использует одну низкую точность или что любая большая модель помещается на бытовой GPU.

Место в Атласе: 3.4; 3.6.

P20. Woosuk Kwon et al.. *Efficient Memory Management for Large Language Model Serving with PagedAttention*. SOSP, 2023.

Эффективное управление памятью при обслуживании LLM с PagedAttention.

Управляет KV-cache блоками, уменьшая потери памяти и поддерживая совместное обслуживание запросов. Это показывает, почему сервер LLM нельзя описать только формулой Transformer. Выигрыш зависит от нагрузки и организации генерации.

Место в Атласе: 3.7; 6.18.

P21. Yaniv Leviathan, Matan Kalman, Yossi Matias. *Fast Inference from Transformers via Speculative Decoding*. ICML, 2023.

Быстрый инференс Transformer со спекулятивным декодированием.

Малая модель предлагает токены, большая проверяет их пакетно. В корректной процедуре можно сохранять целевое распределение генерации. Ускорение зависит от доли принятых предложений и стоимости проверки, поэтому качество черновика имеет системное значение.

Место в Атласе: 3.7.

P22. Yaron Lipman et al.. *Flow Matching for Generative Modeling*. ICLR, 2023.

Согласование потоков для генеративного моделирования.

Обучает векторное поле, задающее перенос распределения. Позволяет связать генеративное обучение с динамическими системами и численным решением ODE. Выбор траектории и решателя является частью метода, а не деталью визуализации.

Место в Атласе: 2.10.

P23. Yang Song et al.. *Consistency Models*. ICML, 2023.

Модели согласованности.

Строят генерацию с малым числом шагов через согласованность точек траектории. Важно различать обучение модели и простое уменьшение шагов готового решателя. Работа углубляет связь качества генерации с вычислительным бюджетом.

Место в Атласе: 2.10.

P24. Alexander Kirillov et al.. *Segment Anything*. ICCV, 2023.

Сегментировать всё.

SAM соединяет модель сегментации, интерфейс подсказок и крупный набор данных. Урок для Атласа — исследовать цикл создания данных вместе с архитектурой. Обобщаемость на домен требует проверки; название не означает универсальность без ошибок.

Место в Атласе: 2.11; 3.1.

P25. Naotian Liu et al.. *Visual Instruction Tuning*. NeurIPS, 2023.

Визуальное обучение следованию инструкциям.

LLaVA связывает зрительное представление с языковой моделью и обучением на инструкциях. Это необходимая ступень от CLIP к диалоговой мультимодальности. Следует различать качество восприятия и убедительность языкового ответа.

Место в Атласе: 2.11; 3.4.

P26. Timo Schick et al.. *Toolformer: Language Models Can Teach Themselves to Use Tools*. NeurIPS, 2023.

Toolformer: языковые модели могут учиться использованию инструментов.

Вызовы инструментов включаются в обучающие данные и отбираются по их полезности для предсказания. Таким образом, выбор действия становится обучаемым поведением. Это не заменяет проверку аргументов, разрешений и внешнего результата.

Место в Атласе: 6.12; 4.1.

P27. Cheng Chi et al.. *Diffusion Policy: Visuomotor Policy Learning via Action Diffusion*. RSS, 2023.

Диффузионная политика: обучение действиям по зрению посредством диффузии.

Диффузионная модель задаёт распределение последовательностей действий робота. Это соединяет генеративные модели с управлением, а не только с медиа. Динамика среды, обратная связь и перенос в физический мир остаются самостоятельными ограничениями.

Место в Атласе: 6.35; 2.10.

P28. Joon Sung Park et al.. *Generative Agents: Interactive Simulacra of Human Behavior*. UIST, 2023.

Генеративные агенты: интерактивные симуляции человеческого поведения.

Память, извлечение, рефлексия и планирование формируют поведение агентов в симуляции. Полезно для архитектуры памяти и взаимодействия. Правдоподобие поведения не равнозначно научной валидности модели общества или надёжности рабочего агента.

Место в Атласе: 6.16; 6.19; 6.20.

Работы 2024 года

P29. Akari Asai et al.. *Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection*. ICLR, 2024.

Self-RAG: обучение извлечению, генерации и критике через саморефлексию.

Обучаемые специальные токены управляют извлечением и оценкой ответа. RAG становится адаптивным процессом вместо неизменной выдачи одинакового числа фрагментов. Внутренняя оценка может ошибаться и требует независимого теста опоры на источники.

Место в Атласе: раздел RAG; 6.26.

P30. Carlos E. Jimenez et al.. *SWE-bench: Can Language Models Resolve Real-World GitHub Issues?*. ICLR, 2024.

SWE-bench: могут ли языковые модели решать реальные задачи GitHub?

Оценивает исправления репозитория по реальным задачам. Единицей анализа становится работа с кодовой базой, а не короткая функция. Результат относится к конкретной версии набора и окружению; его нельзя переносить на всю профессию разработчика.

Место в Атласе: 6.28–6.32.

P31. Omar Khattab et al.. *DSPy: Compiling Declarative Language Model Calls into Self-Improving Pipelines*. ICLR, 2024.

DSPy: компиляция декларативных вызовов LLM в улучшаемые процессы.

Параметризованные модули и оптимизатор заменяют часть ручного подбора промптов. В центре находятся цель, обучающие примеры и граф вычислений. Оптимизация неверной метрики столь же проблематична, как ручная настройка неверного поведения.

Место в Атласе: 6.29; 6.34.

P32. Yijia Shao et al.. *Assisting in Writing Wikipedia-like Articles From Scratch with Large Language Models*. NAACL, 2024.

Помощь в написании энциклопедических статей с нуля с помощью LLM.

STORM организует предварительный поиск и исследование разных перспектив перед написанием статьи. Это важная архитектурная линия Deep Research. Энциклопедический синтез следует отличать от систематического обзора и самостоятельного научного эксперимента.

Место в Атласе: 6.21; 6.22; 6.26.

P33. Minyoung Huh, Brian Cheung, Tongzhou Wang, Phillip Isola. *Position: The Platonic Representation Hypothesis*. ICML, position paper, 2024.

Позиция: платоническая гипотеза представлений.

Объединяет наблюдения о сближении представлений и предлагает гипотезу общей статистической структуры. Это позиционная работа с эмпирической опорой, а не установленный универсальный закон. Читать вместе с калибровочной критикой 2026 года.

Место в Атласе: 2.4.

P34. Albert Gu, Tri Dao. *Mamba: Linear-Time Sequence Modeling with Selective State Spaces*. COLM, 2024.

Mamba: моделирование последовательностей с селективными пространствами состояний.

Селективное состояние и аппаратно ориентированный алгоритм предлагают альтернативу полному вниманию. Важна способность сохранять и отбрасывать информацию в зависимости от входа. Сжатое состояние создаёт собственные компромиссы; это не универсальная замена Transformer.

Место в Атласе: 2.7; 2.8.

P35. Hunter Lightman et al.. *Let's Verify Step by Step*. ICLR, 2024.

Давайте проверять по шагам.

Сравнивает оценку промежуточных шагов и конечного результата на математических задачах. Даёт основу для process reward models. Качество проверяющего и применимость вне исследованной задачи должны рассматриваться отдельно.

Место в Атласе: 4.2.

P36. Yinmin Zhong et al.. *DistServe: Disaggregating Prefill and Decoding for Goodput-optimized Large Language Model Serving*. OSDI, 2024.

DistServe: раздельное исполнение prefill и decoding с оптимизацией полезной пропускной способности.

Разделяет фазы запроса и подбирает ресурсы с учётом требований к задержке. Goodput означает поток запросов, укладывающихся в ограничения обслуживания. Передача KV-cache требует пропускной способности; проверены постановка, размещение и описание экспериментальной среды.

Место в Атласе: 3.7; 6.18.

P37. Victor Quach et al.. *Conformal Language Modeling*. ICLR, 2024.

Конформное языковое моделирование.

Калибрует остановку генерации множества кандидатов и отбор компонентов ответа. Статистическая гарантия для процедуры не означает безошибочности каждой фразы при любом сдвиге данных. Проверены описание метода и связь с контролем риска; доказательства не реплицировались.

Место в Атласе: 1.2; блок 5; 6.32.

P38. Lianmin Zheng et al.. *SGLang: Efficient Execution of Structured Language Model Programs*. NeurIPS, 2024.

SGLang: эффективное исполнение структурированных программ с языковыми моделями.

Соединяет язык описания процесса и среду исполнения, включая переиспользование KV-cache и структурированное декодирование. Для Атласа это мост между программированием агента и инференсом. Правильный формат выхода не обеспечивает правильности содержания.

Место в Атласе: 3.7; 6.11; 6.14.

Работы 2025 года

P39. Junfeng Fang et al.. *AlphaEdit: Null-Space Constrained Knowledge Editing for Language Models*. ICLR, 2025.

AlphaEdit: редактирование знаний с ограничением нулевым пространством.

Проецирует изменение параметров так, чтобы уменьшить влияние на сохраняемые представления. Развивает линию ROME к последовательным правкам. Проверены методическая постановка и ограничения: перенос на мультимодальные и большие reasoning-модели в статье оставлен открытым.

Место в Атласе: 3.4; блок 5.

P40. Xiangyu Qi et al.. *Safety Alignment Should be Made More Than Just a Few Tokens Deep*. ICLR, 2025.

Обучение безопасности должно затрагивать больше первых нескольких токенов.

Исследует поверхностное изменение начальных токенов как источник уязвимости safety alignment. Это связывает безопасность с распределением генерации и устойчивостью последующего дообучения. Улучшение защиты в исследованных случаях не является полной гарантией безопасности.

Место в Атласе: 4.1; блок 5.

P41. Yang Yue et al.. *Does Reinforcement Learning Really Incentivize Reasoning Capacity in LLMs Beyond the Base Model?*. NeurIPS, 2025.

Развивает ли RL способность рассуждать за пределами базовой модели?

Сопоставляет успех одной попытки с покрытием решений при большом числе попыток. В исследованных режимах RLVR рост первого показателя может сочетаться с сужением второго. Проверены выводы и обсуждение: это результат о текущих изученных методах, не теорема о невозможности обучения новым стратегиям.

Место в Атласе: 4.2; 6.32.

P42. Liwei Jiang et al.. *Artificial Hivemind: The Open-Ended Homogeneity of Language Models (and Beyond)*. NeurIPS, Datasets and Benchmarks, 2025.

Искусственное единомыслие: однородность открытых ответов языковых моделей.

Изучает повторяемость ответов внутри модели и сходство между моделями на открытых запросах. Для исследовательского агента это ставит вопрос о разнообразии гипотез и независимости критиков. Сходство результатов не доказывает единого механизма или общего «разума» моделей.

Место в Атласе: 6.19; 6.24; 6.32.

P43. Charlie Snell et al.. *Scaling LLM Test-Time Compute Optimally Can be More Effective than Scaling Parameters for Reasoning*. ICLR, 2025.

Оптимальное увеличение вычислений при ответе может быть эффективнее увеличения параметров для рассуждения.

Сравнивает способы расходования дополнительных вычислений на решение. Эффективная стратегия зависит от трудности вопроса и исходных возможностей модели. Поэтому бюджет рассуждения нужно проектировать адаптивно, а сравнения проводить при сопоставимых ресурсах.

Место в Атласе: 4.2; 6.36.

P44. Yuri Gardinazzi et al.. *Persistent Topological Features in Large Language Models*. ICML, 2025.

Устойчивые топологические особенности больших языковых моделей.

Zigzag persistence отслеживает эволюцию особенностей представлений через слои. Работа даёт прикладной вход в TDA и анализ удаления слоёв. Найденную топологию следует проверять на устойчивость к выборке и параметрам построения комплекса.

Место в Атласе: 1.1; 2.9; блок 5.

P45. Jake C. Snell, Thomas L. Griffiths. *Conformal Prediction as Bayesian Quadrature*. ICML, 2025.

Конформное предсказание как байесовская квадратура.

Предлагает байесовский взгляд на гарантии предсказательной процедуры. Полезна как противовес механическому употреблению слова «гарантия». Авторская критика частотных гарантий требует чтения вместе с их исходной постановкой; это не свидетельство отказа всей теории conformal prediction.

Место в Атласе: 1.2; 1.7.

Работы 2026 года

P46. Tianyu Fu et al.. *Cache-to-Cache: Direct Semantic Communication Between Large Language Models*. ICLR, 2026.

Cache-to-Cache: прямая семантическая коммуникация между LLM.

Обучаемый мост передаёт и объединяет KV-cache двух моделей. Проверены описание механизма и ограничения. Слабый источник может вредить получателю, а масштабирование числа связей остаётся проблемой; стандартного универсального интерфейса результат не устанавливает.

Место в Атласе: 6.19; 3.7.

P47. Fabian Gröger, Shuo Wen, Maria Brbić. *Revisiting the Platonic Representation Hypothesis: An Aristotelian View*. ICML, 2026.

Пересмотр платонической гипотезы представлений: аристотелевский взгляд.

Корректирует смещения метрик сходства, связанные с масштабом сети. Глобальная картина существенно меняется; локальное согласие соседств сохраняется, расстояний — нет. Это основание изучать измерительную процедуру вместе с геометрической гипотезой.

Место в Атласе: 2.4; 1.2.

P48. Zhanlin Ni et al.. *The Flexibility Trap: Rethinking the Value of Arbitrary Order in Diffusion Language Models*. ICML, 2026.

Ловушка гибкости: пересмотр произвольного порядка генерации в диффузионных LLM.

Исследует, как свободный порядок генерации может обходить неопределённые точки ветвления и снижать разнообразие решений. Упрощение порядка используется в JustGRPO. Это мотивирует отдельную подтему диффузии текста; нельзя переносить результат на все модели и задачи.

Место в Атласе: 2.10; 4.2.

P49. Pascal Bergsträsser, Ryan Cotterell, Anthony W. Lin. *Transformers are Inherently Succinct*. ICLR, 2026.

Transformer обладают внутренне компактным представлением.

Сравнивает компактность описания формальных языков Transformer, автоматами и LTL. Формальный результат о выразительности связан с трудностью проверки свойств. Обучаемость, практическое обобщение и возможность верифицировать ограниченную систему — отдельные вопросы; проверена аннотация, не все доказательства.

Место в Атласе: 1.7; 2.5; 6.14.

P50. John X. Morris et al.. *How much can language models memorize?*. ICML, название в программе отличается от arXiv, 2026.

Как много могут запоминать языковые модели?.

Связывает измерение запоминания с информационной ёмкостью. В программе ICML используется can, на доступной карточке arXiv — do; это зафиксированное различие версий. Включена как приоритет для углубления; числовые оценки ёмкости и доказательства в данном обзоре не проверены.

Место в Атласе: 1.3; 1.7; блок 5.

Открытые участки карты

Отдельного отбора по годам ещё требуют: причинное представление и идентифицируемость; continual learning и machine unlearning; теория offline/online RL; автоматическое доказательство теорем; векторные и гибридные индексы из DB-сообщества; потоковые речевые агенты; OCR научных документов; человеческая оценка исследовательских систем. Перечисление этих направлений не означает, что они отсутствуют в Атласе: по текущей выборке нельзя судить о полноте их библиографии.

Следующее расширение должно идти по этим пробелам, а не добавлением ещё десятков похожих LLM-статей из одной конференции. Нужны также отрицательные результаты и репликации для каждой сильной формулировки. Например, подтверждение локального сходства не является доказательством переносимости навыка, прохождение тестов не является доказательством отсутствия дефектов, а статистическая гарантия не снимает её предпосылок.